LinkiaFP

PLANTILLA: Entrega de Actividades

6-27_1_1_M-IA_5074_Sistemas de Big Data

MASTER IA & BIG DATA

Curso académico 2026/2027 - Edición Online

Acceso al repositorio de ejercicios para el Módulo actual sobre Sistemas de Big Data
https://github.com/dcueli-com/bigdata_sys.git

Tema 3: Configuración de Cuadros de Mando y Técnicas Predictivas

Índice

1. Ejercicio 1
   a. ***Acceso al repositorio para el ejercicio***
   b. *Describe tres KPIs que podrían ser relevantes para el análisis de datos en el sector sanitario.*
   c. *Para cada KPI, explica qué tipo de gráfico sería adecuado para visualizarlo en un cuadro de mando.*
   d. *Describe un ejemplo específico de cómo se podrían utilizar los datos y las visualizaciones para mejorar la calidad de la atención médica.*
      i. Subsistema Comercial
         - Ventas
         - Compras
   e. Diccionario
2. Ejercicio 5
   a. Carga el archivo CSV y realiza una exploración inicial de los datos
      i. *Acceso al repositorio para el ejercicio*
      ii. Preparación del entorno de desarrollo
   b. Identifica y maneja los problemas de calidad de datos
      i. Análisis de Valores ausentes o Nulos
         ➢ *Resultados del Análisis*
      ii. Análisis de Valores no válidos
         - Análisis de Fechas no válidas

Nota:
Todos tenemos una elaborada lista de principios y conforme pasan los años pueden extenderse o resumirse, pero particularmente dos de mis principios más básicos es ser lo más sincero y honesto «posible», aunque ahora digo que «te permitan» y siempre que sea recíproco. Además, tengo que decir que en mi experiencia laboral nunca he gestionado, desarrollado y en general colaborando en proyectos relacionados con la Sanidad.

Puesto en contexto, toda esta información que aporto en los ejercicios ha sido obtenida, como ya no puede ser de otro modo, de herramientas IA como son Gemini, ChatGpt y Perplexity, pero que quede claro que no por ello, «lo ha hecho la IA», que el que busca la información, desarrolla, escribe y aprende es un servidor «orgánico».

[Ir al índice]

EJERCICIO 1: Análisis de Datos en el Sector Sanitario.
Un hospital quiere analizar los datos de sus pacientes para optimizar la atención médica.

Es lógico pensar que se le pida los KPIs más comunes a algunas de las herramientas y, como todas, el resultado ha sido justo el mismo, pero claro con otro entreno porque la consecución de palabras ha sido distinta, aunque, al fin y al cabo, lo mismo. Así pues, con otra entrada lo que he pedido es un listado completo de KPIs según las áreas de gestión de un hospital, ordenado por esas áreas, con una corta definición y un índice (otro) de usabilidad diaria. ¿El resultado? Dejo el enlace al repositorio de este módulo de Sistemas de Big data, que es más fácil que poner una tabla con unas cuantas filas.

Acceso a hoja de cálculo de KIPs de área de gestión hospitalaria del el SNS adaptado al ejercicio:
https://github.com/dcueli-com/bigdata_sys/.../KIPs-area-gestion-hospitalaria.xlsx

Describe tres KPIs que podrían ser relevantes para el análisis de datos en el sector sanitario.
[Ir al índice]

A continuación, se listan los KPIs que he seleccionado para este ejercicio. Cabe destacar la lectura de las aclaratorias de final del mismo, que cuanto menos sería de interés general —podría haber dicho *perturbadoras* pero creo que sería demasiado sensacionalista—

KPI Evolución de la plantilla sanitaria pública
Mide la variación del número de profesionales sanitarios que trabajan en el sistema público a lo largo del tiempo. Se podría obtener un análisis más preciso distinguiendo categorías profesionales, como *medicina*, *enfermería* y otras profesiones sanitarias.
Analizar su evolución podría servir para identificar posibles reducciones o incrementos de personal, detectar necesidades de contratación y estudiar si la disponibilidad de profesionales evoluciona de forma acorde con la demanda asistencial. Además, añadiría información relevante sobre la evolución de las listas de espera y de la carga de trabajo de los profesionales.

Se calcula habitualmente como la tasa de variación porcentual del personal estatutario activo entre dos periodos evaluados (ej. medición interanual o trimestral) para medir la ganancia o pérdida real de fuerza laboral.

$$Evolución\ (\%) = \left(\frac{P_f - P_i}{P_i}\right) \times 100$$

P_i, plantilla en período anterior
P_f, plantilla en período actual

Hay un análisis publicado en el sitio web Gaceta Sanitaria indicando el aumento de un 31,5% de la plantilla de la sanidad pública española entre 2014 y 2023.
Gaceta Sanitaria, recursos humanos de la sanidad pública

No sé hasta qué punto estos informes son fiables desde la fuente, en tanto y cuanto haya financiaciones de empresas u organizaciones privadas, así como, por así decirlo, «organismos públicos», interesados en el beneficio propio o en contra de las cifras.

KPI, Porcentaje del gasto sanitario público destinado a conciertos
Proporción del gasto sanitario público que se destina a contratar servicios prestados por entidades privadas mediante conciertos sanitarios. Un aumento sostenido en el tiempo de esta métrica evidenciaría matemáticamente la desviación de financiación de la red pública hacia la privada.

Se calcula mediante la siguiente fórmula:
\[\text{Porcentaje de conciertos}= \frac{\text{Gasto sanitario público en conciertos}} {\text{Gasto sanitario público total}}\times100 \]
Relevancia: permite analizar cómo evoluciona la distribución de los recursos públicos entre la prestación directa de servicios sanitarios y la contratación de proveedores externos. Su seguimiento ayuda a identificar cambios en el modelo de gestión, comparar diferencias entre comunidades autónomas y estudiar qué peso adquiere la colaboración con entidades privadas en la financiación de la asistencia sanitaria.
Este indicador no demuestra por sí solo que exista una privatización ni permite determinar si la atención mejora o empeora, pero aporta información relevante para estudiar la evolución del sistema sanitario.
Gráfico recomendado: gráfico de líneas. Representar el porcentaje anual permite observar su evolución y detectar incrementos o reducciones. También se pueden utilizar varias líneas para comparar comunidades autónomas.
KPI 3. Porcentaje de actividad sanitaria externalizada

Descripción: mide la proporción de una actividad sanitaria financiada públicamente que realizan proveedores externos, en lugar de prestarse directamente con recursos propios del sistema público. Para calcularlo, es necesario delimitar previamente una actividad concreta, como las pruebas diagnósticas o las intervenciones quirúrgicas, y disponer de datos comparables sobre la actividad total y la externalizada.
\[\text{Actividad externalizada (\%)}= \frac{\text{Actividad externalizada}} {\text{Actividad sanitaria total}}\times100 \]
Relevancia: permite conocer qué parte de determinadas prestaciones sanitarias se realiza mediante contratación externa y analizar cómo cambia esa distribución a lo largo del tiempo. Combinado con información sobre tiempos de espera, costes y resultados clínicos, ayuda a evaluar si la externalización contribuye a mejorar la capacidad asistencial y la atención a los pacientes.
A diferencia del gasto en conciertos, este indicador se centra en la actividad realizada, no en el dinero destinado a financiarla. Para que las comparaciones sean válidas, deben mantenerse los mismos criterios de cálculo y el mismo ámbito asistencial.
Gráfico recomendado: gráfico de barras. Permite comparar el porcentaje de actividad externalizada entre distintos servicios sanitarios o comunidades autónomas. Si se dispone de una serie histórica homogénea, también sería adecuado un gráfico de líneas para estudiar su evolución.
Fuentes oficiales de referencia
Para respaldar el trabajo, puedes utilizar estas dos fuentes del Ministerio de Sanidad:

- *Estadística de Gasto Sanitario Público*: ofrece información sobre el gasto sanitario público y sus componentes, incluidos los conciertos.
- *Evaluación de la sanidad privada en el sistema sanitario de España (2025)*: analiza la participación de los proveedores privados en el Sistema Nacional de Salud y aporta datos sobre centros, camas, financiación y actividad.

Una precisión metodológica: para el tercer KPI conviene elegir una actividad concreta antes de calcularlo, porque no hay que confundir la actividad realizada por centros privados financiada públicamente con el conjunto de la actividad pública externalizada.

Nota:
La Ley 16/2003 establece que los indicadores de calidad y seguridad deben servir para evaluar y comparar los centros sanitarios, públicos y privados, mediante criterios homogéneos y fiables.
Boletín Oficial del Estado, Ley 16/2003, de 28 de mayo

Los KPI clínicos habituales no permiten demostrar por sí solos que se esté privatizando la sanidad. Para estudiar esa tendencia habría que analizar también quién presta los servicios, quién los financia y cómo evolucionan los recursos públicos y privados.
El Ministerio de Sanidad publicó en diciembre de 2025 un informe específico sobre la participación privada en el sistema sanitario español. Entre sus resultados, señala que los hospitales de titularidad privada integrados en el SNS pasaron de 106 en 2011 a 145 en 2023. También analiza el crecimiento de la financiación pública de la actividad prestada por centros privados.

Publicación de diciembre de 2025 del informe Evaluación de la sanidad privada en el sistema sanitario de España. Este analiza, entre otros aspectos, hospitales y camas de titularidad privada integrados en el SNS, financiación pública de centros privados y actividad asistencial
Ministerio de Sanidad, Gabinete de prensa

Estos indicadores deben estudiarse conjuntamente y a lo largo del tiempo. Por ejemplo, un aumento del gasto contratado con centros privados puede indicar una mayor dependencia de proveedores externos, pero para evaluar sus consecuencias también habría que analizar el volumen y la complejidad de los casos atendidos, los costes comparables y los resultados clínicos.
El propio informe ministerial identifica dificultades de transparencia y la falta de un sistema suficientemente homogéneo para comparar los resultados de las distintas fórmulas de gestión.
Evaluación de la sanidad privada en el sistema sanitario de España 2025

¿Habría un patrón en los KPIs que observe la tendencia a la privatización?
Sí. Desde la analítica de datos, la tendencia a la privatización no se mide como una conspiración, sino como una **correlación matemática y empírica entre dos conjuntos de KPIs**:

1. **Deterioro de KPIs operativos públicos:** Se observa un aumento sostenido en el Tiempo Medio de Espera (TME), en las Listas de Espera Quirúrgica (LEQ) y una saturación crónica del Índice de Ocupación de Camas (IOC) en la red pública.
2. **Aumento de KPIs financieros de externalización:** Cuando los KPIs operativos públicos superan los umbrales críticos de seguridad, la administración activa de forma automática el KPI presupuestario de **"Tasa de Derivación o Conciertos"**. Esto es el porcentaje de presupuesto público que se transfiere a clínicas privadas para operar o hacer pruebas diagnósticas que el hospital público no puede absorber.

El patrón analítico es claro: El estrangulamiento o la falta de recursos en los indicadores de capacidad pública (intencionado o no) justifica matemáticamente la ejecución de partidas presupuestarias hacia el sector privado. Al mismo tiempo, en el macroentorno de datos, este deterioro público correlaciona directamente con el aumento interanual del KPI de "Penetración de Seguros de Salud Privados" en España. Son hechos medibles en el Portal Estadístico del Ministerio de Sanidad y del INE.

Para cada KPI, explica qué tipo de gráfico sería adecuado para visualizarlo en un cuadro de mando. *[Ir al índice]*

KPI Evolución de la plantilla sanitaria pública
Gráfico de líneas. Representar el número de profesionales por año permite identificar tendencias, cambios y periodos de crecimiento o reducción. Se pueden utilizar líneas diferentes para cada categoría profesional.

Describe un ejemplo específico de cómo se podrían utilizar los datos y las visualizaciones para mejorar la calidad de la atención médica. *[Ir al índice]*

Diccionario

INCLASNS
Son los **In**dicadores **Cla**ve del **S**istema **N**acional de **S**alud que recogen las métricas de rendimiento sobre salud, accesibilidad, calidad, seguridad, uso de recursos y gasto, entre otros. No son exclusivamente indicadores internos de gestión hospitalaria: algunos miden resultados de salud de la población y otros, el funcionamiento del sistema sanitario.
Documentación - Indicadores Clave del sistema Nacional de Salud [*inclasns.sanidad.gob.es*]
Lista (Anexo II) - Indicadores Clave del sistema Nacional de Salud [*inclasns.sanidad.gob.es*]

SIAE
Es el **S**istema de **I**nformación de **A**tención **E**specializada que recoge información sobre recursos, actividad, personal y datos económicos de hospitales públicos y privados.
Consulta interactiva del SNS [*pestadistico.inteligenciadegestion.sanidad.gob.es*]
Análisis Actividad Asistencial [*www.sanidad.gob.es*]

RAE-CMBD
Registro de **A**ctividad de Atención Sanitaria **E**specializada y permite estudiar indicadores hospitalarios como estancia media, reingresos, mortalidad, infecciones hospitalarias y hospitalizaciones potencialmente evitables.
iCMBD: indicadores y ejes de análisis del CMBD

EJERCICIO 3: Análisis del Dataset Iris.

Acceso al repositorio para el ejercicio *[Ir al índice]*
https://github.com/dcueli-com/bigdata_sys/tree/develop/src/activities/RA1/lesson_01

1. ***Carga el dataset Iris: Carga el dataset Iris usando pandas.read_csv().***
2. ***Histograma multivariable: Crea un histograma que muestre la distribución de cada una de las cuatro características (sepal_length, sepal_width, petal_length, petal_width) para cada especie.***
3. ***Diagrama de dispersión con pares: Utiliza sns.pairplot() para crear un diagrama de dispersión que muestre la relación entre cada par de características. Agrega color a los puntos para diferenciar las especies.***
4. ***Mapa de calor de correlación: Crea un mapa de calor que muestre la correlación entre las diferentes características del dataset.***
5. ***Gráfico de violín: Crea un gráfico de violín (violinplot) para cada una de las características (sepal_length, sepal_width, petal_length, petal_width), agrupado por especie.***

Extrae conclusiones sobre el por qué de los resultados obtenidos.

EJERCICIO 4: Creación de un cuadro de mando con Power BI.
Utiliza Power BI para crear un cuadro de mando que muestre la evolución de las ventas de una empresa de productos electrónicos durante los últimos 5 años. Los datos de ventas se encuentran en una tabla de Excel con las siguientes columnas:

- ***Fecha (AAAA-MM-DD)***
- ***Producto***
- ***Cantidad Vendida***
- ***Precio Unitario***
- ***Ingresos (Cantidad Vendida * Precio Unitario)***

a) Crea una tabla que muestre la cantidad total vendida por producto y año.
b) Crea un gráfico de líneas que muestre la evolución de los ingresos totales por año.
c) Crea un mapa de calor que muestre las ventas por producto y año. Los colores más intensos indicarán mayores ventas.
d) Agrega un filtro a tu cuadro de mando para que el usuario pueda seleccionar un producto específico y ver su evolución de ventas a lo largo de los años

Desde mi punto de vista y por mi experiencia, cabe comentar que todo diseño *es muy subjetivo* y dicho esto, voy a seguir el proceso sobre los tres niveles de abstracción que se pide.



Figura 1.

Diseño de un modelo conceptual que incluya las entidades principales (por ejemplo, Producto, Cliente, Pedido) *[Ir al índice]*
Partimos del enfoque básico del enunciado original de la práctica, donde se propone las entidades genéricas de ejemplo *Producto, Cliente y Pedido*. Mi propuesta resultante de diseño se orienta a un entorno cercano a lo real de Big Data e ingeniería de datos, añadiendo la trazabilidad de existencias, control de proveedores múltiples, gestión de almacenes físicos y diferenciación entre los flujos, ventas, compras y los propios movimientos logísticos puros.

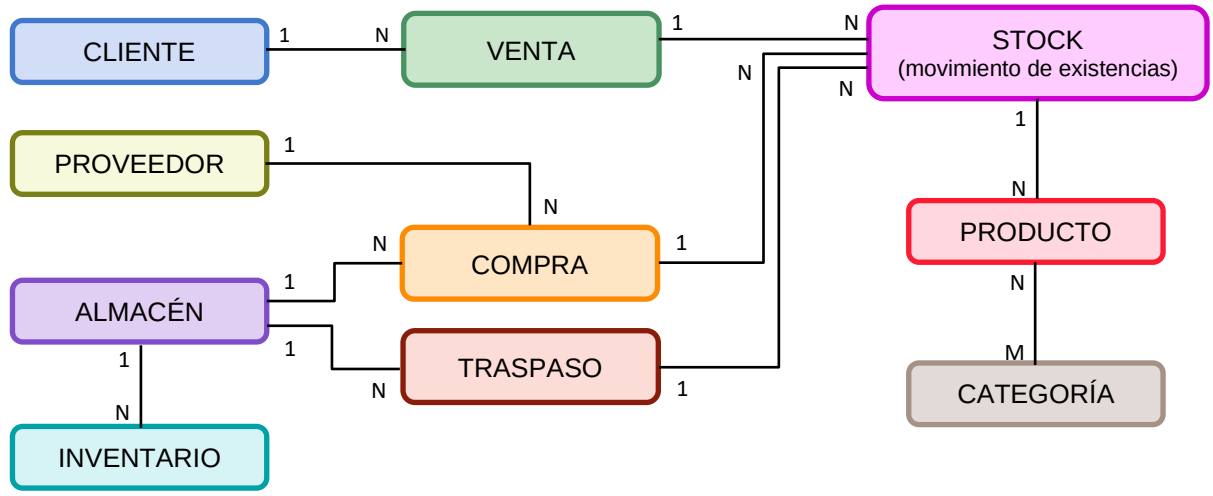


Figura 2.

Para acercar el sistema al rigor profesional y escalabilidad, el modelo evoluciona hacia una arquitectura de "inventario doble" estructurado en subsistemas interconectados, donde el comercial y el logístico convergen la entidad Stock, el libro de movimientos.

Subsistema Comercial

1. Ventas

- **Entidades:** CLIENTE y VENTA.
- El cliente interactúa con la plataforma generando órdenes de VENTA. Cada venta representa un flujo salida que impacta directamente en el inventario a través de una relación de detalle (1:N con STOCK), permitiendo auditar qué unidades físicas exactas de qué productos salieron del sistema para atender un pedido.

2. Compras

- **Entidades:** PROVEEDOR, ALMACÉN y COMPRA.
- A diferencia de un modelo básico, se define rigurosamente que es el ALMACÉN el que emite las órdenes de COMPRA a los PROVEEDORES. Esto permite gestionar costes de adquisición variables, tiempos de entrega y múltiples fuentes de suministro para un mismo producto.

Subsistema Logístico (Traspasos Internos entre almacenes)

- **Entidad:** ALMACÉN y TRASPASO.
- Se añade valor a la carencia crítica en la mayoría de diseños donde el movimiento de mercancía entre diferentes centros logísticos (ALMACÉN) propios de un mismo sistema (una empresa). Utilizando los atributos para el ALMACÉN origen y ALMACÉN destino se genera un TRASPASO de forma controlada con una salida y una entrada simultáneas en el stock.

Subsistema de Control de existencias (el Inventariado)

- **Entidad:** INVENTARIO y ALMACÉN
- Desacoplado de la operativa transaccional diaria de venta, se vincula al ALMACÉN exclusivamente para la realización de recuentos físicos periódicos para auditorías de control de existencias, evitando bloqueos de concurrencia en tiendas.

Taxonomía de PRODUCTO

Se añade igualmente categorización a la entidad PRODUCTO mediante CATEGORÍA con una relación flexible **N:M**, permitiendo multiclases para facilitar tanto la experiencia de usuario en aplicativos como en los análisis agregados de demanda en proyectos de Big Data.

STOCK (Libro de movimientos)

Todas las operaciones que impliquen movimiento de PRODUCTO, como las vistas anteriormente VENTA, COMPRA y TRASPASO, convergen en la entidad central **STOCK**. En lugar de almacenar un

número de existencias propenso a inconsistencias, la entidad actúa como un libro de asientos donde se registra cada movimiento sea de entrada y/o salida asociada a un PRODUCTO y un ALMACÉN. El stock actual se calcula dinámicamente o se audita a partir de estos movimientos.

En resumen, se añade valor por la cercanía del diseño a la realidad de la lógica de negocio de un Sistema de Planificación de recursos Empresariales. Ni que decir tiene que todo es escalable hasta el punto de modularizar para separar aplicativos del propio ERP entre gestión, logística, contabilidad y un CRM. Por esto en la siguiente sección, el Modelo Lógico, solo se indican recomendaciones básicas para los atributos, tipos de datos y restricciones.

Basándote en el modelo conceptual, crea un modelo lógico detallando atributos y relaciones *[Ir al índice]*
A partir del modelo conceptual previo, se define el **modelo lógico** estructurado en tablas normalizadas en su Tercera Forma Normal (3FN), especificando las claves primarias (PK), claves foráneas (FK), atributos, tipos de datos recomendados y las restricciones de integridad.

Criterios de Diseño y Estandarización
El modelo lógico se traduce el diseño conceptual previo a una estructura relacional normalizada en Tercera Forma Normal (3FN), optimizada para entornos transaccionales.
Se han aplicado los siguientes convenios para la ingeniería:

- **Nomenclatura**
  Se ha utilizado la convención *snake_case* para columnas, se pluralizan los nombres de tablas para corresponder a las colecciones de entidades además de que esto puede evitar colisiones con palabras reservadas de los motores SQL.

- **Tipos de Datos y Dimensionamiento**
  Se siguen mis propias directrices para optimización de memoria y almacenamiento, respecto a los campos de tipo VARCHAR donde se acota utilizando potencias de dos (16, 32, 64, 128, etc.) así se garantiza una asignación eficiente de bloques en disco.

Subsistemas Estructurales

Taxonomía de producto
La relación multiclase entre productos y categorías se resuelve mediante la tabla asociativa *product_categories*, permitiendo una clasificación flexible del catálogo sin redundancias y se incorpora el campo *sku* como identificador alfanumérico único por producto además el campo *slug* también como identificador alfabético único en las categorías para garantizar que los aplicativos tengan URLs amigables y un rendimiento óptimo en búsquedas de comercio electrónico.

categories (CATEOGRÍA)
- **id** (INT, PK)
- name (VARCHAR(64), NOT NULL)
- *slug* (VARCHAR(32), UNIQUE, NOT NULL)
- description (TEXT, NULL)

products (PRODUCTO)
- **id** (INT, PK)
- *sku* (VARCHAR(32), UNIQUE, NOT NULL)
- name (VARCHAR(128), NOT NULL)
- description (TEXT, NULL)
- base_price (DECIMAL(10,2), NOT NULL)

product_categories (Categorías de producto Tabla Asociativa N:M)
- ***product_id*** (INT, PK, FK -> products.id)
- ***category_id*** (INT, PK, FK -> categories.id)

Subsistema de comercial

Compras

La tabla *purchases* gestiona el aprovisionamiento externo coordinado por el almacén con los diferentes proveedores (*suppliers*), permitiendo la trazabilidad de costes y entregas.

suppliers (PROVEEDOR)

- **id** (INT, PK)
- fiscal_name (VARCHAR(128), NOT NULL)
- tax_id (VARCHAR(32), UNIQUE, NOT NULL)
- contact_name (VARCHAR(64), NULL)
- email (VARCHAR(64), NULL)

purchases (COMPRA)

- **id** (INT, PK)
- ***supplier_id*** (INT, NOT NULL, FK -> suppliers.id)
- ***warehouse_id*** (INT, NOT NULL, FK -> warehouses.id)
- purchase_date (TIMESTAMP, NOT NULL)
- status (VARCHAR(32), NOT NULL)

Ventas

La tabla *sales* actúa como cabecera de los pedidos de los clientes, vinculada de forma unívoca con la tabla de clientes (*customers*).

customers (CLIENTE)

- **id** (INT, PK)
- first_name (VARCHAR(64), NOT NULL)
- last_name (VARCHAR(64), NOT NULL)
- *email* (VARCHAR(64), UNIQUE, NOT NULL)
- phone (VARCHAR(32), NULL)

sales (VENTA)

- **id** (INT, PK)
- ***customer_id*** (INT, NOT NULL, FK -> customers.id)
- sale_date (TIMESTAMP, NOT NULL)
- status (VARCHAR(32), NOT NULL)

Subsistema Logístico

La entidad ALMACÉN queda modelada conforme a centros de distribución (*warehouses*), aislando recuentos físicos para auditorías de control periódico mediante la tabla para la colección de inventarios (inventories).
Además los movimientos entre almacenes (*warehouses*), los traslados de mercancía, quedan estructurados en la tabla *transfers*, con las respectivas claves foráneas que indican el almacén de salida y el almacén de entrada, quedando así registrado el origen y destino del movimiento logístico.

warehouses (ALMACÉN)

- **id** (INT, PK)
- name (VARCHAR(64), NOT NULL)
- location (VARCHAR(128), NOT NULL)

transfers (TRASPASO)

- **id** (INT, PK)
- ***warehouse_out_id*** (INT, NOT NULL, FK -> warehouses.id)
- ***warehouse_in_id*** (INT, NOT NULL, FK -> warehouses.id)
- transfer_date (TIMESTAMP, NOT NULL)

inventories (INVENTARIO)

- **id** (INT, PK)
- ***warehouse_id*** (INT, NOT NULL, FK -> warehouses.id)
- audit_date (TIMESTAMP, NOT NULL)
- notes (TEXT, NULL)

El núcleo transaccional lo recoge la entidad STOCK y con su tabla *stock_moves* resolvemos:

- problemas de inconsistencia a los campos estáticos de cantidad,
- que cada variación de inventario (generada por una venta, una compra, un traspaso o un ajuste de inventario) se quede registrada como una línea con un valor positivo (entrada) o negativo (salida) y
- con las claves foráneas (*sale_id*, *purchase_id*, *transfer_id*) tenemos trazabilidad bidireccional entre el movimiento físico del almacén y el evento comercial o logístico que lo originó.

stock_moves (STOCK)

- **id** (INT, PK)
- ***warehouse_id*** (INT, NOT NULL, FK -> warehouses.id)
- ***product_id*** (INT, NOT NULL, FK -> products.id)
- quantity (INT, NOT NULL) -- Positivo para entradas, negativo para salidas
- movement_type (VARCHAR(32), NOT NULL)
- ***sale_id*** (INT, NULL, FK -> sales.id)
- ***purchase_id*** (INT, NULL, FK -> purchases.id)
- ***transfer_id*** (INT, NULL, FK -> transfers.id)
- movement_date (TIMESTAMP, NOT NULL)

Podemos un esquema en la Figura 3

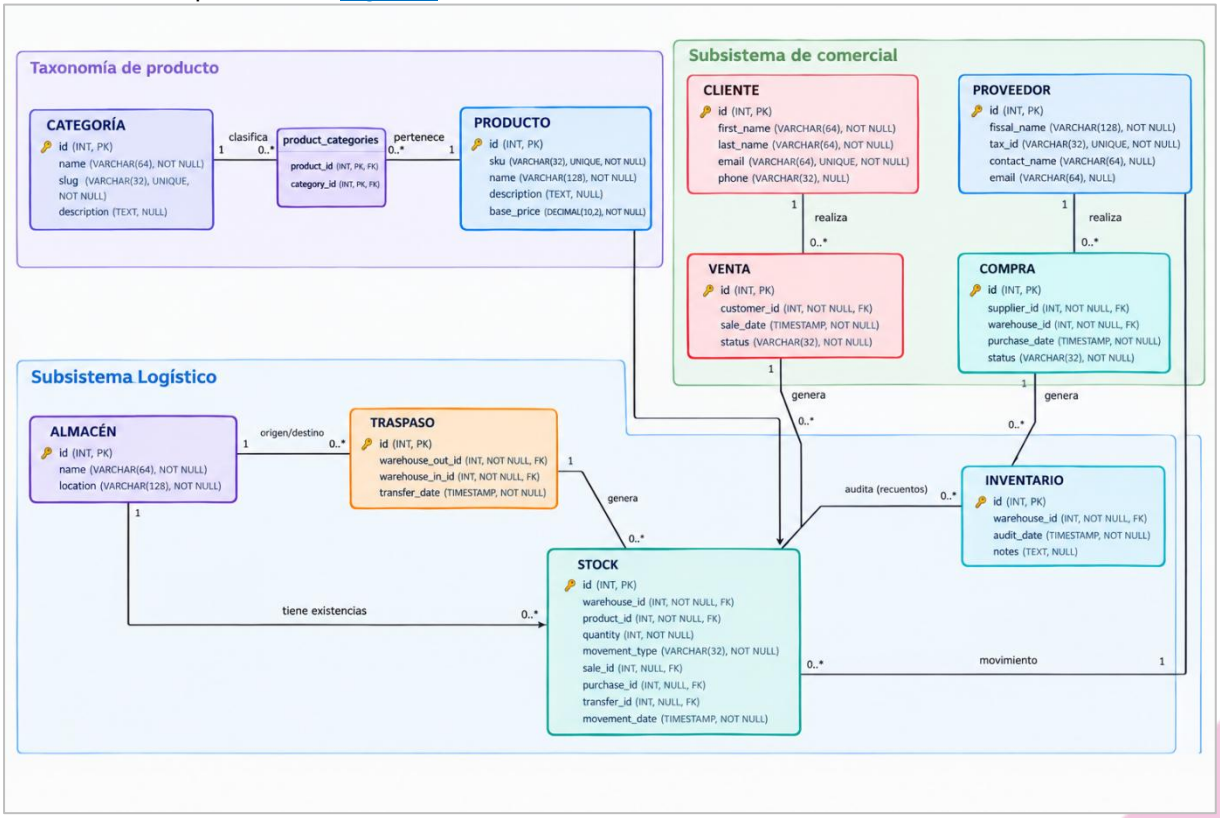


Figura 3.

Desarrolla un modelo físico para una base de datos relacional, especificando tipos de datos y claves *[Ir al índice]*

Acceso al script SQL:
https://github.com/dcueli-com/bigdata_sys/blob/develop/src/activities/RA1/lesson_02/scripts/2_1_DDL_DML.sql

Script DDL está escrito SQL estándar (ANSI SQL, compatible con PostgreSQL, MySQL y MariaDB) donde se traduce todas las tablas, tipos de datos, claves primarias, claves foráneas y restricciones de integridad del modelo lógico anterior.
Ha sido ejecutado y probado en MySQL 8.4.4 (LTS) sobre MySQL Workbench v8.0.46

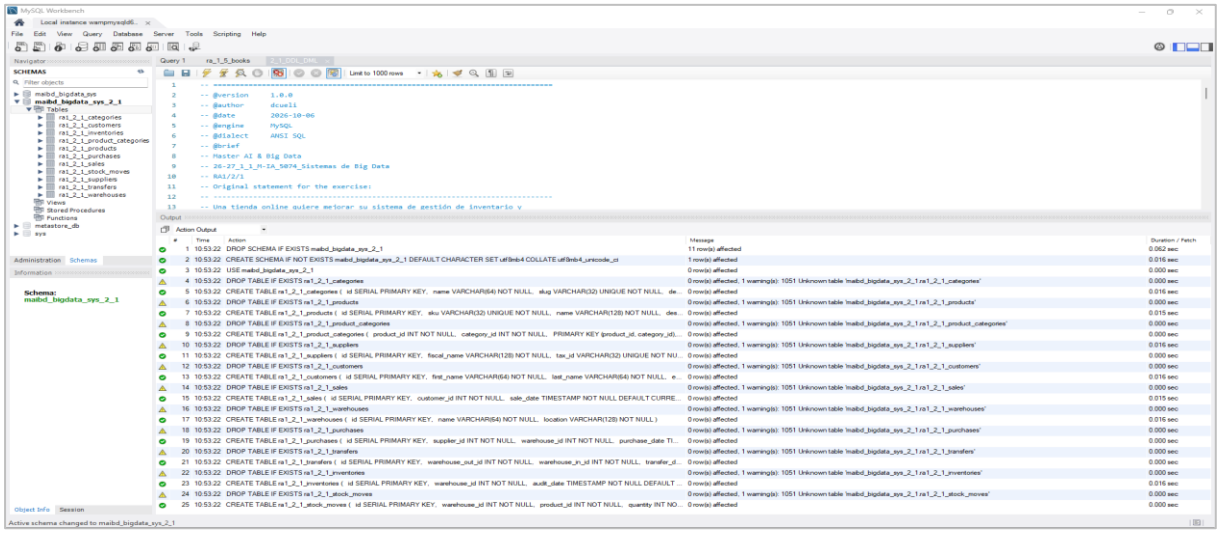


Figura 4.

Igualmente ha sido ejecutado y probado en Programiz

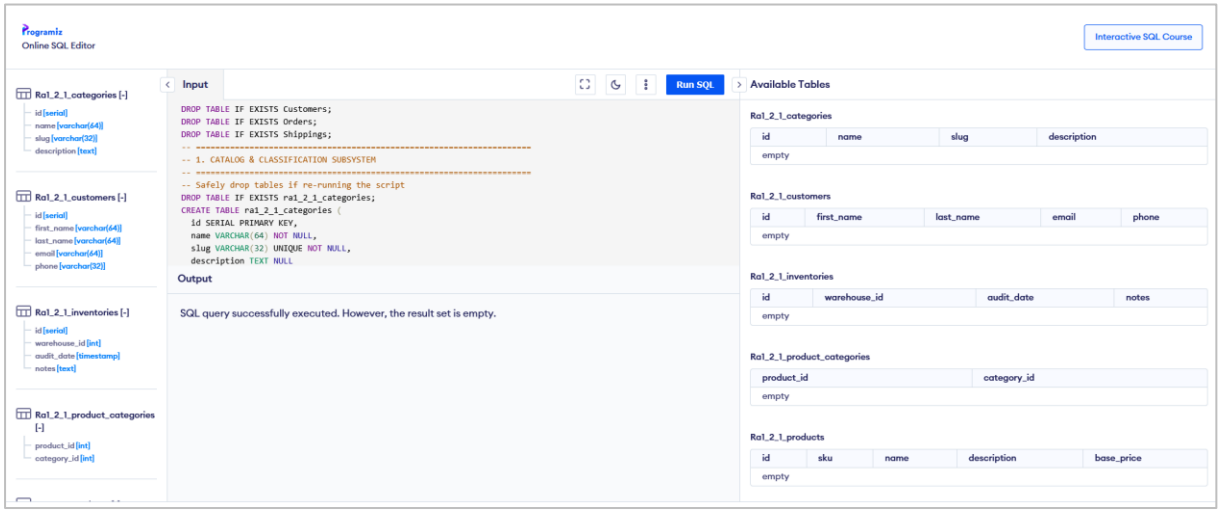


Figura 5.

Script SQL del modelo físico

```sql
-- 1. SCHEMA CREATION
-- ========================================================================
-- Safely drop schema
DROP SCHEMA IF EXISTS maibd_bigdata_sys_2_1;
-- Create target schema with full UTF8 encoding support (only for MYSQL/MariaDB)
CREATE SCHEMA IF NOT EXISTS maibd_bigdata_sys_2_1 DEFAULT CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci;
USE maibd_bigdata_sys_2_1;

-- ========================================================================
-- 1. CATALOG & CLASSIFICATION SUBSYSTEM
-- ========================================================================
DROP TABLE IF EXISTS ra1_2_1_categories;
CREATE TABLE ra1_2_1_categories (
  id SERIAL PRIMARY KEY,
  name VARCHAR(64) NOT NULL,
  slug VARCHAR(32) UNIQUE NOT NULL,
  description TEXT NULL
);

DROP TABLE IF EXISTS ra1_2_1_products;
CREATE TABLE ra1_2_1_products (
  id SERIAL PRIMARY KEY,
  sku VARCHAR(32) UNIQUE NOT NULL,
  name VARCHAR(128) NOT NULL,
  description TEXT NULL,
  base_price DECIMAL(10, 2) NOT NULL
);

DROP TABLE IF EXISTS ra1_2_1_product_categories;
CREATE TABLE ra1_2_1_product_categories (
  product_id INT NOT NULL,
  category_id INT NOT NULL,
  PRIMARY KEY (product_id, category_id),
  CONSTRAINT fk_pc_product FOREIGN KEY (product_id) REFERENCES ra1_2_1_products(id) ON DELETE CASCADE,
  CONSTRAINT fk_pc_category FOREIGN KEY (category_id) REFERENCES ra1_2_1_categories(id) ON DELETE CASCADE
);

-- ========================================================================
-- 2. SUPPLIERS & PROCUREMENT SUBSYSTEM
-- ========================================================================
DROP TABLE IF EXISTS ra1_2_1_suppliers;
CREATE TABLE ra1_2_1_suppliers (
  id SERIAL PRIMARY KEY,
  fiscal_name VARCHAR(128) NOT NULL,
  tax_id VARCHAR(32) UNIQUE NOT NULL,
  contact_name VARCHAR(64) NULL,
  email VARCHAR(64) NULL
);

-- ========================================================================
-- 3. COMMERCIAL & CUSTOMER SUBSYSTEM
-- ========================================================================
DROP TABLE IF EXISTS ra1_2_1_customers;
CREATE TABLE ra1_2_1_customers (
  id SERIAL PRIMARY KEY,
  first_name VARCHAR(64) NOT NULL,
  last_name VARCHAR(64) NOT NULL,
  email VARCHAR(64) UNIQUE NOT NULL,
  phone VARCHAR(32) NULL
);

DROP TABLE IF EXISTS ra1_2_1_sales;
CREATE TABLE ra1_2_1_sales (
  id SERIAL PRIMARY KEY,
  customer_id INT NOT NULL,
  sale_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
  status VARCHAR(32) NOT NULL,
  -- e.g., 'PAID', 'SHIPPED', 'COMPLETED'
  CONSTRAINT fk_sale_customer FOREIGN KEY (customer_id) REFERENCES ra1_2_1_customers(id)
);
```

```sql
-- ========================================================================
-- 4. LOGISTICS SUBSYSTEM
-- ========================================================================
DROP TABLE IF EXISTS ra1_2_1_warehouses;
CREATE TABLE ra1_2_1_warehouses (
  id SERIAL PRIMARY KEY,
  name VARCHAR(64) NOT NULL,
  location VARCHAR(128) NOT NULL
);


DROP TABLE IF EXISTS ra1_2_1_purchases;
CREATE TABLE ra1_2_1_purchases (
  id SERIAL PRIMARY KEY,
  supplier_id INT NOT NULL,
  warehouse_id INT NOT NULL,
  purchase_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
  status VARCHAR(32) NOT NULL,
  -- e.g., 'PENDING', 'RECEIVED', 'CANCELLED'
  CONSTRAINT fk_purchase_supplier FOREIGN KEY (supplier_id) REFERENCES ra1_2_1_suppliers(id),
  CONSTRAINT fk_purchase_warehouse FOREIGN KEY (warehouse_id) REFERENCES ra1_2_1_warehouses(id)
);

DROP TABLE IF EXISTS ra1_2_1_tranfers;
CREATE TABLE ra1_2_1_transfers (
  id SERIAL PRIMARY KEY,
  warehouse_out_id INT NOT NULL,
  warehouse_in_id INT NOT NULL,
  transfer_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
  CONSTRAINT fk_transfer_warehouse_out FOREIGN KEY (warehouse_out_id) REFERENCES ra1_2_1_warehouses(id),
  CONSTRAINT fk_transfer_warehouse_in FOREIGN KEY (warehouse_in_id) REFERENCES ra1_2_1_warehouses(id)
);

DROP TABLE IF EXISTS ra1_2_1_inventories;
CREATE TABLE ra1_2_1_inventories (
  id SERIAL PRIMARY KEY,
  warehouse_id INT NOT NULL,
  audit_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
  notes TEXT NULL,
  CONSTRAINT fk_inventory_warehouse FOREIGN KEY (warehouse_id) REFERENCES ra1_2_1_warehouses(id)
);

-- ========================================================================
-- 5. stock_moves
-- ========================================================================
DROP TABLE IF EXISTS ra1_2_1_stock_moves;
CREATE TABLE ra1_2_1_stock_moves (
  id SERIAL PRIMARY KEY,
  warehouse_id INT NOT NULL,
  product_id INT NOT NULL,
  quantity INT NOT NULL,
  -- Positive for inflows, negative for outflows
  movement_type VARCHAR(32) NOT NULL,
  -- e.g., 'SALE', 'PURCHASE', 'TRANSFER_OUT', 'TRANSFER_IN', 'INVENTORY_ADJUSTMENT'
  sale_id INT NULL,
  purchase_id INT NULL,
  transfer_id INT NULL,
  movement_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
  CONSTRAINT fk_stock_warehouse FOREIGN KEY (warehouse_id) REFERENCES ra1_2_1_warehouses(id),
  CONSTRAINT fk_stock_product FOREIGN KEY (product_id) REFERENCES ra1_2_1_products(id),
  CONSTRAINT fk_stock_sale FOREIGN KEY (sale_id) REFERENCES ra1_2_1_sales(id),
  CONSTRAINT fk_stock_purchase FOREIGN KEY (purchase_id) REFERENCES ra1_2_1_purchases(id),
  CONSTRAINT fk_stock_transfer FOREIGN KEY (transfer_id) REFERENCES ra1_2_1_transfers(id)
);
```

[Ir al índice]

EJERCICIO 5: Una empresa de comercio electrónico está implementando un sistema de análisis de ventas en tiempo real. Como parte de este proyecto, necesitan asegurar la calidad de los datos que alimentarán su sistema. Se te ha proporcionado un archivo CSV llamado 'ventas_con_problemas.csv' que contiene datos de ventas de los últimos 30 días. Este archivo contiene varios problemas de calidad de datos que deben ser identificados y corregidos. Tu tarea es desarrollar un script en Python que realice las siguientes operaciones:

1. ***Carga el archivo CSV y realiza una exploración inicial de los datos.***
2. ***Identifica y maneja los siguientes problemas de calidad de datos:***
    a. ***Valores nulos en campos críticos (fecha, producto, cantidad, precio_unitario, total)***
    b. ***Fechas inválidas***
    c. ***Valores negativos en campos numéricos (cantidad, precio_unitario, total)***
    d. ***Inconsistencias en el cálculo del total (comparando cantidad * precio_unitario con el total registrado)***
    e. ***Valores atípicos (outliers) en campos numéricos***
    f. ***Duplicados***
3. ***Implementa técnicas de limpieza de datos para corregir o eliminar los problemas identificados.***
4. ***Genera un informe que incluya:***
    a. ***Número de filas originales vs. número de filas después de la limpieza***
    b. ***Cantidad de problemas identificados y corregidos por cada tipo***
    c. ***Estadísticas descriptivas de los datos limpios (media, mediana, desviación estándar) para campos numéricos***
5. ***Crea visualizaciones que ayuden a entender la distribución de los datos y los efectos de la limpieza.***
6. ***Guarda los datos limpios en un nuevo archivo CSV.***

Módulos que pueden usar: pandas, numpy, matplotlib, seaborn

Carga el archivo CSV y realiza una exploración inicial de los datos *[Ir al índice]*

Acceso al repositorio para el ejercicio
https://github.com/dcueli-com/bigdata_sys/blob/develop/src/activities/RA1/lesson_02/notebooks/2_5_1_analysing_dataset.ipynb
https://github.com/dcueli-com/bigdata_sys/blob/develop/src/activities/RA1/lesson_02/scripts/2_5_1_analysing_dataset.py

Bueno, como soy de la vieja escuela, he abierto el CSV con Excel, formateado y por supuesto creado el filtro. Una vez hecho esto, le he echado una visual, y se observan los **315 registros** que contiene el archivo además de la primera fila como cabecera de las 5 columnas: *fecha*, *producto*, *cantidad*, *precio_unitario* y *total*; y como no podía ser de otro modo, de mi primer análisis exploratorio mediante juicio experto, se desprende que el dataset presenta múltiples fallos sintácticos, semánticos y de integridad estructural, a mi entender bastante severos, como son: *valores nulos o faltantes*, *fechas inválidas y/o erróneas*, *valores negativos o cero* en las columnas numéricas, *outliers o valores atípicos*, y más casos que seguramente aparecerán cuando le haga una auditoría automatizada.

Preparación del entorno de desarrollo *[Ir al índice]*
Lo primero será ejecutar un análisis completo y para ello vamos a instalar en el entorno las distintas herramientas que sugiere el enunciado de la práctica: *pandas*, *numpy*, *matplotlib*, *seaborn*.

El entorno de desarrollo es ***Debian 13 (Trixie)*** bajo ***WSL*** en ***Windows 11 Pro 25H2*** con el *gestor de versiones* de Python ***pyenv*** y usando la versión 3.13.7 del lenguaje del entorno virtual, aunque como se puede observar en la Figura 0 los distintos kernel de Python están sincronizados para evitar confusiones.

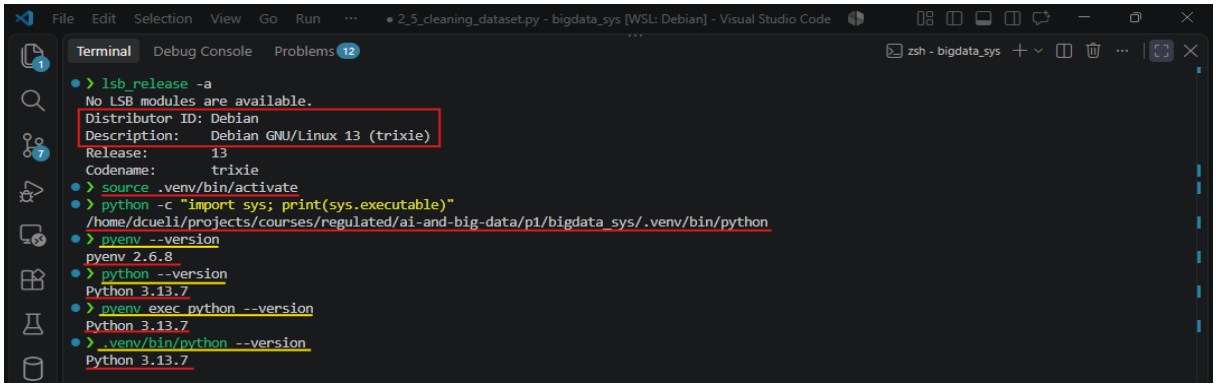


Figura 0.

Instalamos las bibliotecas *Pandas*, *Numpy*, *Matplotlib* y *Seaborn*.

```
pip install pandas numpy matplotlib seaborn
```

Una vez instalado todo podremos manipular, validar y visualizar los diferentes resultados así que cargamos el conjunto de datos del archivo CSV

```
dataset: str = DATA_DIR / "ventas_con_problemas.csv"
df = pd.read_csv(dataset)
```

Identifica y maneja los problemas de calidad de datos *[Ir al índice]*

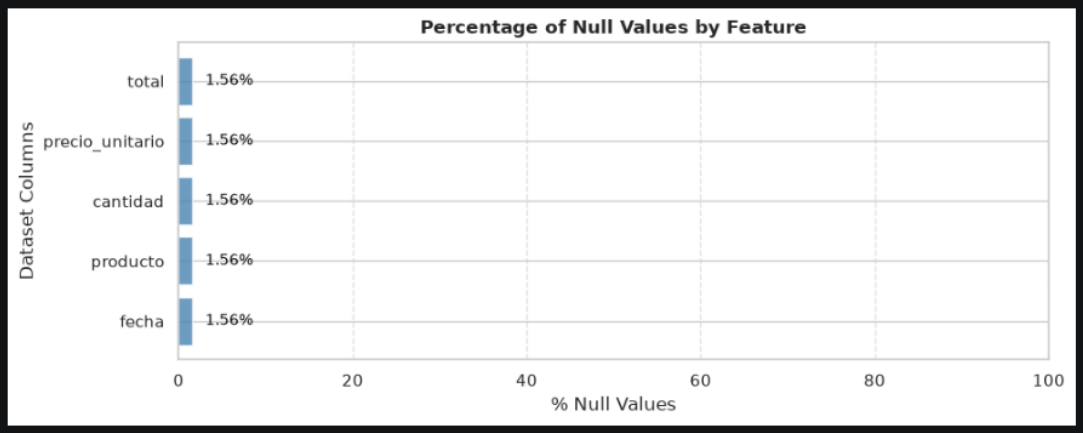
Análisis de Valores ausentes o Nulos
Vamos a inspeccionar exactamente qué columnas tienen valores nulos y cuántos registros están afectados en cada una. Para ello, ejecutamos el código relacionado en la celda con título:

```
# DATA ANALYSIS, 1. CHECK OF NULL VALUES
# ======================================
```

Obteniendo la siguiente información que se puede observar en la Figura 1:

```
# DATA ANALYSIS, 1. CHECK OF NULL VALUES ···

+ ======================================================
+ CHECK OF NULL VALUES
+ ------------------------------------------------------
Null values per column:
fecha             5
producto          5
cantidad          5
precio_unitario   5
total             5
dtype: int64
+ ------------------------------------------------------
Total rows with at least one null value:
25
+ ------------------------------------------------------
```




```
+ ------------------------------------------------------
+ Time to load: 0.2345 seconds
+ ======================================================
```

Figura 1.

Resultados del Análisis de ausentes (o nulos) *[Ir al índice]*
Como análisis final, se han encontrado **5 valores nulos** en cada una de las 5 columnas, lo que corresponde a 5 filas con nulos totales o vacías en esos campos. Estos datos incompletos pueden dificultar el análisis de las ventas y deben revisarse antes de utilizar el conjunto de datos para elaborar informes o tomar decisiones.

En total, hay **25 incidencias de ausentes o nulos** repartidas en **25 filas**, lo que representa el **7,81% de** las **320 filas** del conjunto de datos, que deben ser tratadas, bien eliminándolas por ser registros incompletos críticos, o bien aplicándolas sólo si así se indica en la lógica de negocio.

La recomendación en estos casos es comprobar si los valores ausentes o nulos pueden recuperarse a partir de otras fuentes o si es necesario excluir los registros afectados.

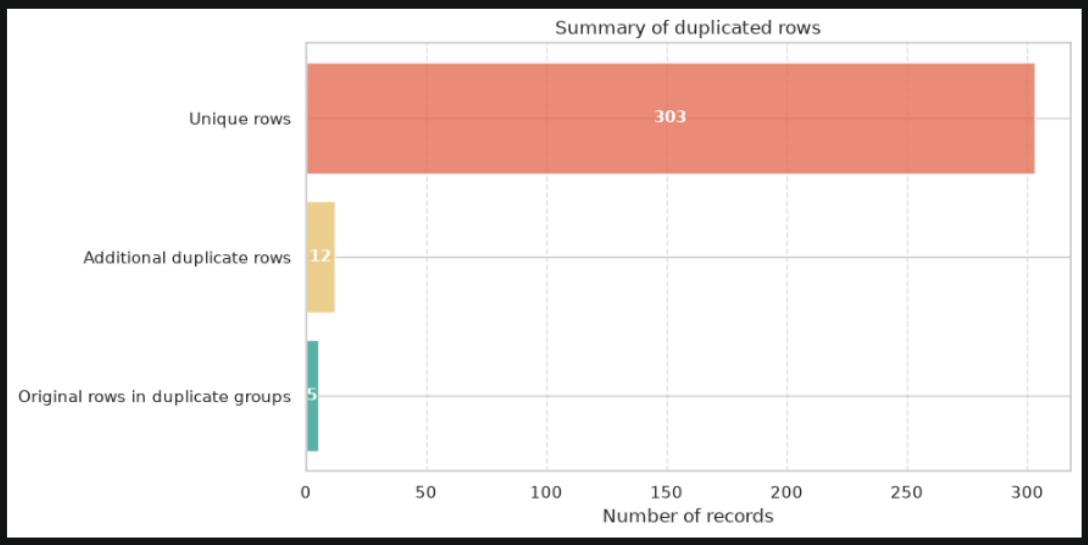
Análisis de Valores duplicados *[Ir al índice]*
Usando el método `.duplicated()` de la biblioteca Pandas, buscamos filas enteras que sean **exactamente iguales** a una anterior, por lo que vamos a usarla indicando el parámetro `keep=False`, que nos marcará todas las repeticiones de las filas duplicadas para poder inspeccionarlas a fondo. Por otra parte, también podemos contar cuántas filas están repetidas en total.
Ejecutamos el script de la celda:

```
# DATA ANALYSIS, 2. CHECK OF DUPLICATED VALUES
# ============================================
```

Teniendo la salida:

```
# DATA ANALYSIS, 2. CHECK OF DUPLICATED VALUES ⋯
+ ============================================================
+ CHECK OF DUPLICATED VALUES
+ Summary of fully duplicate rows found
+ ------------------------------------------------------------
Just duplicated rows: 12
Source duplicated rows : 5
+ ------------------------------------------------------------
Snapshot duplicated rows: 17

          fecha            producto  cantidad  precio_unitario   total
117  2026-09-24        Funda tablet       2.0            11.14   22.28
315  2026-09-24        Funda tablet       2.0            11.14   22.28
116  2026-10-08    Teclado mecanico       2.0           103.16  206.32
282  2026-10-08    Teclado mecanico       2.0           103.16  206.32
301  2026-10-08    Teclado mecanico       2.0           103.16  206.32
119  2026-10-10       Disco SSD 1TB       2.0           103.23  206.46
175  2026-10-10       Disco SSD 1TB       2.0           103.23  206.46
239  2026-10-10       Disco SSD 1TB       2.0           103.23  206.46
118  2026-10-12  Monitor 24 pulgadas       4.0           127.06  508.24
148  2026-10-12  Monitor 24 pulgadas       4.0           127.06  508.24
217  2026-10-12  Monitor 24 pulgadas       4.0           127.06  508.24
265  2026-10-12  Monitor 24 pulgadas       4.0           127.06  508.24
120  2026-10-17           Webcam HD       2.0            68.97  137.94
122  2026-10-17           Webcam HD       2.0            68.97  137.94
192  2026-10-17           Webcam HD       2.0            68.97  137.94
318  2026-10-17           Webcam HD       2.0            68.97  137.94
319  2026-10-17           Webcam HD       2.0            68.97  137.94
```




```
+ ------------------------------------------------------------
+ Time to load: 0.2200 seconds
+ ============================================================
```

Figura 2.

De la que podemos obtener las siguientes conclusiones para el tratamiento de los datos.

Resultado del Análisis de Valores duplicados *[Ir al índice]*
Para este resultado, se ha optado por un gráfico de barras con el número de registros según su situación de duplicidad. Se muestran los recuentos absolutos, ya que interesa saber cuántas filas están afectadas.
Con los datos que hemos obtenido, claramente la interpretación es:

TIPO DE REGISTRO	FILAS
Filas sin duplicidad (únicas)	303
Filas originales pertenecientes a grupos duplicados	***5***
Filas duplicadas adicionales	***12***
TOTAL	320

Esta distribución presupone que «*las filas originales pertenecientes a grupos duplicados:* ***5***» son las filas originales y que las 12 filas duplicadas son las copias adicionales. Dicho de otro modo, se han detectado exactamente **12 registros** completamente duplicados en columnas clave (*fecha*, *producto*, *cantidad*, *precio_unitario* y *total*).
La ventaja de esta representación es que diferencia dos conceptos que pueden confundirse:

- *12 duplicados adicionales son las filas repetidas que sobran si conservamos una aparición de cada registro.*
- 17 filas afectadas son la suma de las 5 apariciones originales más las 12 repeticiones.

Así, el gráfico permite ver de un vistazo que hay 17 filas implicadas en duplicidades, pero que eliminar únicamente las repeticiones supondría retirar 12 filas, no 17.

La duplicidad de estos registros puede ser debido a fallos en la captura de datos como reintentos fallidos de peticiones HTTP de envíos de formularios o incluso solapamientos al exportar los datos desde la base de datos origen.

Dejar estos 12 registros en el dataset final inflaría artificialmente las estadísticas en cuanto a facturación, las unidades vendidas, etc; lo que se deduce que suprimir estas duplicidades sería lo más apropiado de cara a futuros análisis e informes.

Análisis de Integridad en el Cálculo del Totales *[Ir al índice]*
En un registro correcto, la multiplicación de la `cantidad` por el `precio_unitario` debe ser igual al total grabado en la celda y como en el análisis previo se han observado valores nulos o faltantes, vamos a verificar qué volumen de inconsistencias tiene el dataset en cuanto a la columna `total` se refiere.
Los pasos que llevaremos a cabo serán:

- Calculamos una nueva columna temporal `total_temp`, aquí es importante decir que no tendré en cuenta el signo:

$$total_tmp = cantidad \times precio_unitario$$

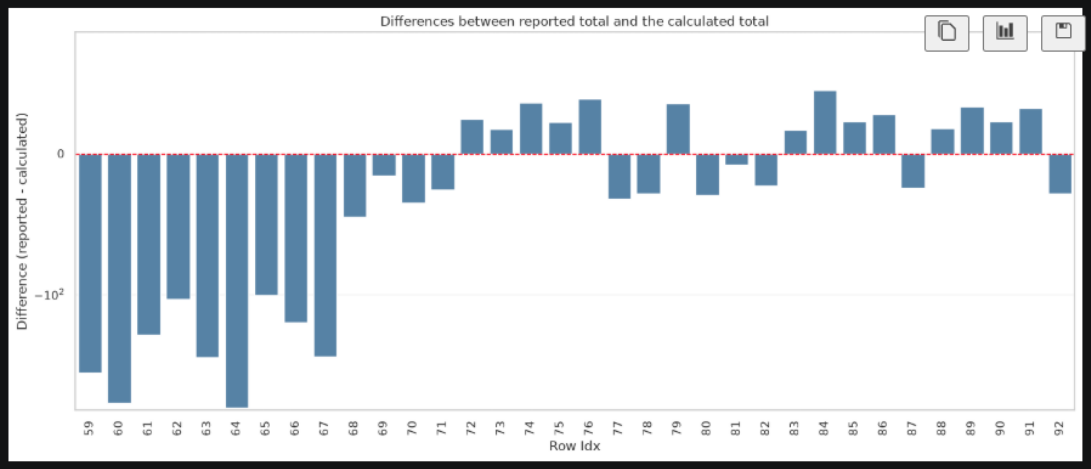
- Comparamos `total_temp` con la columna `total` existente.
- Contamos cuántas filas no coinciden, y para esto es el no tener en cuenta el signo

Ejecutamos el script de la celda:

```
# DATA ANALYSIS, 3. CHECK OF COLUMN VALUE TOTAL
# ============================================
```

Una vez que ejecutado el script, obtenemos la siguiente salida de la Figura 3:

```
+ ============================================================
+ CHECK OF TOTAL COLUMN VALUE
+ Summary of rows with incorrect Total amount:
+ ------------------------------------------------------------
Rows with different totals: 34
+ ------------------------------------------------------------
Snapshot of rows with inconsistent total calculation:
            producto  cantidad  precio_unitario   total  total_temp
59   Teclado mecanico       3.0            69.24 -207.72      207.72
60      Disco SSD 1TB       3.0           120.63 -361.89      361.89
61       Funda tablet       3.0            34.92 -104.76      104.76
62   Altavoz portatil       1.0            54.69  -54.69       54.69
63   Altavoz portatil       4.0            39.26 -157.04      157.04
64   Teclado mecanico       4.0            98.12 -392.48      392.48
65            Hub USB       3.0            16.89  -50.67       50.67
66  Raton inalambrico       2.0            41.59  -83.18       83.18
67   Teclado mecanico       3.0            52.02 -156.06      156.06
68   Teclado mecanico       1.0           107.74   62.83      107.74
```




```
Note:
-----
The chart shows the differences between the reported total in
the CSV and the calculated total obtained by multiplying the
quantity by the unit price for each product. Negative values
indicate that the reported total is lower than the calculated
total, while positive values indicate that it is higher; a
symmetric logarithmic scale is used on the Y-axis to make
differences of varying magnitudes easier to visualize.
+ ------------------------------------------------------------
+ Time to load: 0.6204 seconds
+ ============================================================
```

Figura 3.

`Nota:`
El gráfico representa las diferencias entre el total registrado en el CSV y el total calculado a partir de la cantidad y el precio unitario de cada producto. Los valores negativos indican que el total registrado es inferior al calculado, y los positivos, que es superior; se utiliza una escala simétrica logarítmica en el eje Y para facilitar la visualización de diferencias de distinta magnitud.

Resultados del Análisis de Integridad en el Cálculo de Totales *[Ir al índice]*

Vemos **34 filas con inconsistencias en el cálculo del total**.
Como se observa en la instantánea de la Figura 3, en 10 filas se encuentran dos tipos de errores muy claros que alimentan las 34 discrepancias entre el *total calculado* (`total_temp`) y el *total registrado* (`total`):

1. **Fallo de integridad en los signos negativos (filas 59 a 67)**
   Ya en el primer registro de la instantánea, la cantidad es positiva (`3`) y el precio unitario es positivo (`69.24`), pero el *total registrado* (`total`) aparece en negativo (`-207.72`) cuando debería ser positivo (`207.72`).
2. **Discrepancia en los cálculos puros (fila 68)**
   Un teclado mecánico con cantidad (`1`) y precio unitario (`precio_unitario`) registrado de (`107.74`) da un total esperado de (`107.74`), pero en la columna `total` figura erróneamente otro importe (`62.83`).

Los valores incorrectos deben corregirse tras verificar su origen, evitando sustituirlos automáticamente si no se puede confirmar cuál es el dato correcto. Por tanto, *se recomienda revisar los 34 registros afectados y recalcular el importe a partir de la cantidad y el precio unitario, siempre que estos datos sean fiables.*

Análisis de Valores no válidos *[Ir al índice]*
Aunque a simple vista puedan parecer que son dos análisis distintos, yo he decidido unificarlos en el mismo gráfico, aunque cada uno tenga a su vez su propio análisis.

Análisis de Fechas no válidas *[Ir al índice]*
Como a primera vista, he detectado fechas con formato inválido, nulos, ausentes o valores que no son de tipo fecha, voy a analizaros primero.

Estas situaciones suelen ocurrir cuando en los aplicativos, la introducción en los sistemas es libre, es decir, la entrada en el cuadro de texto es abierta y se permite escribir cualquier cosa y, además, en la definición de la columna en la BDD se indica un tipo igualmente abierto, como por ejemplo de tipo texto, véase `VARCHAR(12)`, o `String`, o `Text` en No-SQL, que ni que decir tiene que, normalmente, es un grave error. Si a eso le sumamos la capacidad digital de un orangután que tienen los usuarios, podemos ver escrita cualquier cosa en las celdas de fecha.

En este conjunto de datos en concreto, nos encontramos con varios tipos de errores graves en la columna fecha:

1. **Texto literal inválido**
   Hay filas donde en lugar de una fecha aparecen palabras como "ayer" o "no_es_fecha". Ningún lenguaje puede convertir un texto así en una fecha real.
2. **Fechas con Meses o días fuera de rango**
   - Por ejemplo, aparece `2026-02-30`, `31/02/2026`, o `2026-10-45`.
   - Meses que no existen, como por ejemplo `2026-13-10`.
3. **Celdas vacías (valores nulos)**
   Filas donde directamente no hay fecha registrada.

Para limpiar las fechas de forma segura, utilizamos la función `to_datetime()` de la biblioteca Pandas. Esta función lee el valor e intenta convertirlo a un formato de fecha real (YYYY-MM-DD). Si encuentra un texto extraño, que no puede convertir como un valor nulo, una fecha fuera de rango, o texto puro “`no_es_fecha`”, se le indica que **no dé error**, sino que lo convierta en un valor **`NaN`** para poder detectarlo y eliminarlo, o corregirlo más adelante.

Ejecutamos la celda:

```
# DATA ANALYSIS, 4. CHECK OF INVALID DATE VALUES
# ==============================================
```

Y la ejecución del script da la siguiente salida:

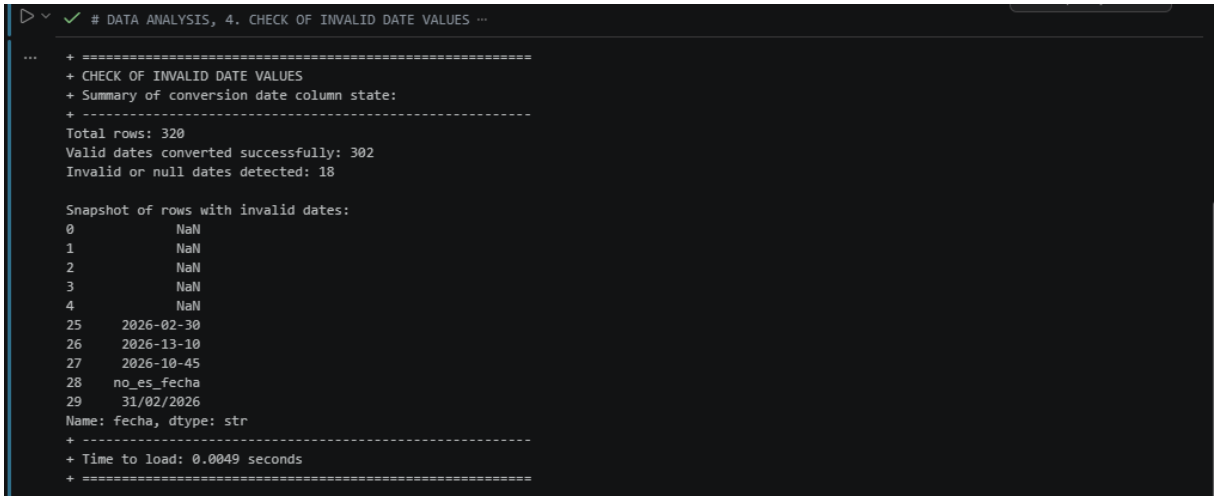


Figura 4.

Análisis de Valores numéricos no válidos *[Ir al índice]*
Una vez ya comprobados los valores nulos (*25 filas afectadas*) y las fechas corruptas (*13 filas con fechas no válidas*), el siguiente problema a revisar en la calidad de los datos son los **valores negativos o cero** en los campos numéricos (`cantidad`, `precio_unitario` y `total`), los cuales no tienen sentido en un registro comercial de movimientos de salida o, dicho de otro modo, más comúnmente movimientos de ventas.

Si entendemos que el dataset aportado procede de un sistema de comercio electrónico, no pueden o no deberían existir precios unitarios negativos, ni totales iguales a cero. Por otra parte, en cuanto a importe de ventas, es decir, a totales se refiere, pueden existir perfectamente con cantidades negativas, pero puede suceder incluso que existan errores de signo.

La solución a importes negativos pasaría por consultar con el dpto. comercial, ventas o administrativo que, normalmente son las entidades dentro de la compañía a las que compete estos asuntos. Un importe negativo representa una devolución siempre y cuando exista un documento de salida (facturas de ventas) con una Serie de numeración explícita y exclusiva para ello. Por tanto, puede ser que existan registros inconsistentes o devoluciones mal registradas sin documento rectificativo asociado, así que se descartaría del dataset para no distorsionar las métricas.

De otra forma, aunque no es el caso, podríamos actuar asumiendo que un registro es rectificativo si, y sólo si, cumple los siguientes requisitos:

1. que en el dataset apareciese la columna cliente,
2. hay un único movimiento para el mismo cliente con la misma cantidad, mismo producto, mismo precio unitario y, por estos dos últimos, el mismo importe (total) en positivo y,
3. según fecha del movimiento, sea anterior al negativo.

Para dar por zanjado este tema, en estas situaciones estaríamos obligados a consultar a las personas y/o departamentos relacionados con la extracción del dataset, o bien, saber que en un dataset nunca, o al menos, nunca deberían estar mezclados las ventas ordinarias y las devoluciones en la misma tabla con signos positivos y negativos ya que podría dar lugar a distorsiones de las métricas de rendimiento de producto, como ya comenté anteriormente.

Con todo esto, ya he dado una pista de la solución que voy a aplicar.

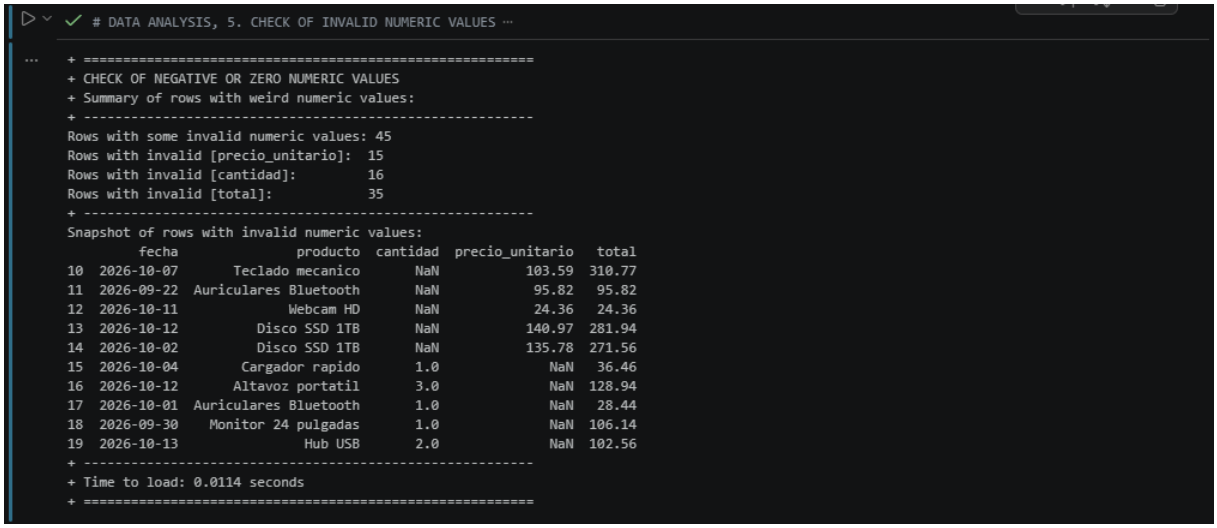
Una vez aclarados los términos, el script para verificar los valores numéricos debe:

- Convertir las columnas `cantidad`, `precio_unitario` y `total` a tipo numérico de forma segura.
- Buscar y mostrar cuántas filas tienen valores menores o iguales a cero (≤ 0) en cada una de esas 3 columnas.
- Mostrar algunos ejemplos de esas filas para ver el problema de cerca.

Ejecutamos el script de la siguiente celda:

```
# DATA ANALYSIS, 5. CHECK OF INVALID NUMERIC VALUES
# ================================================
```

Podemos ver la salida en la siguiente captura de pantalla:



```
# DATA ANALYSIS, 5. CHECK OF INVALID NUMERIC VALUES ⋯
+ ========================================================
+ CHECK OF NEGATIVE OR ZERO NUMERIC VALUES
+ Summary of rows with weird numeric values:
+ --------------------------------------------------------
Rows with some invalid numeric values: 45
Rows with invalid [precio_unitario]:  15
Rows with invalid [cantidad]:         16
Rows with invalid [total]:            35
+ --------------------------------------------------------
Snapshot of rows with invalid numeric values:
         fecha               producto  cantidad  precio_unitario   total
10  2026-10-07       Teclado mecanico       NaN           103.59  310.77
11  2026-09-22  Auriculares Bluetooth       NaN            95.82   95.82
12  2026-10-11             Webcam HD       NaN            24.36   24.36
13  2026-10-12          Disco SSD 1TB       NaN           140.97  281.94
14  2026-10-02          Disco SSD 1TB       NaN           135.78  271.56
15  2026-10-04        Cargador rapido       1.0              NaN   36.46
16  2026-10-12       Altavoz portatil       3.0              NaN  128.94
17  2026-10-01  Auriculares Bluetooth       1.0              NaN   28.44
18  2026-09-30    Monitor 24 pulgadas       1.0              NaN  106.14
19  2026-10-13                Hub USB       2.0              NaN  102.56
+ --------------------------------------------------------
+ Time to load: 0.0114 seconds
+ ========================================================
```

Figura 5.

Resultados de los Análisis *[Ir al índice]*

Resultados del Análisis de fechas no válidas

La salida que vemos en la Figura 3 confirma al 100% lo que se ha comentado en el análisis previo y se puede ver claramente y de forma limpia los ***5 registros vacíos iniciales (***`NaN`***)*** y *los* ***13 errores de fecha*** (`2026-02-30`, `2026-13-10`, `no_es_fecha`, `31/02/2026`, etc.), sumando exactamente las **18 incidencias**.

Resultados del Análisis de Valores numéricos no válidos

Por la Figura 5 se pueden distinguir **45 registros con al menos un valor numérico no válido**. La columna **`total`** es la que presenta más incidencias, **con 35 registros afectados**, seguida de **`cantidad`** con **16** y **`precio_unitario`** con **15**. Cabe destacar que estas cifras pueden solaparse, ya que un mismo registro puede contener errores en varias columnas, por este motivo, no deben sumarse para calcular el total de registros afectados.

En la gráfica que se ha desarrollado, Figura 6, se muestra el porcentaje de *registros correctos* y *con errores* en cada columna (`fecha`, `cantidad`, `precio_unitario` y `total`), lo que permite comparar la calidad de los datos independientemente del número de incidencias detectadas en cada columna. Se observa que la columna total concentra la mayor proporción de registros con valores no válidos.

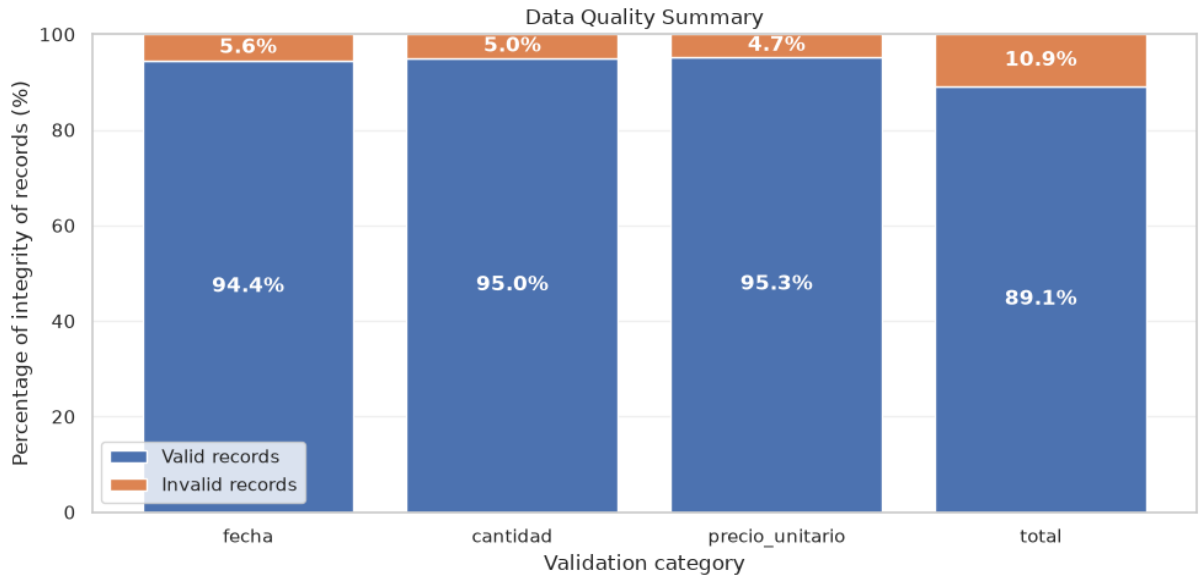


Figura 6.

Se recomienda, primero, tener en cuenta la recomendación del apartado de Resultados del Análisis de Integridad en el Cálculo de Totales para seguidamente revisar los valores ausentes, nulos, cero o negativos. Los valores solo deben corregirse a partir de fuentes fiables antes de utilizar estos datos para los análisis posteriores. Si no es posible recuperarlos, los registros afectados deberían ser excluidos de los análisis que dependan de esos datos.

Análisis de Valores atípicos (Outliers) *[Ir al índice]*
Sabiendo que los *outliers* son valores que se escapan drásticamente de lo que son los rangos normales de un dato en concreto, y estando en un análisis de datos de comercio electrónico, como en el que más o menos nos encontramos, voy a considerar valores atípicos los casos donde, por ejemplo, un producto como un Cargador o un Ratón, aunque sean de Apple, aparecen con precios que rondan entre los 5.000€ o 10.000€, o una funda para una Tablet tenga un precio de más de 3000€, o, ya por terminar, compras masivas anómalas de cientos de unidades de golpe en una sola línea. En resumen, la cantidades o importes de una distribución normal en las transacciones de nuestro dataset.

Una forma estándar y muy visual de detectar *outliers* es utilizando el **IQR** o inspeccionando los valores extremos (por ejemplo, el percentil 95 o 99) de las columnas `cantidad` y `precio_unitario`.

Ejecutando las

```
# DATA ANALYSIS, 7. CHECK OF OUTLIERS VALUES
# ==========================================
```

Y en la Figura 7 tenemos la salida que produce la ejecución anterior

```
+ ============================================================
+ CHECK OF OURLIERS VALUES
+ Summary of rows with possible outlier values on Price and Quantity:
+ ------------------------------------------------------------
Quantity highest values: 5

          fecha          producto  cantidad  precio_unitario     total
97   2026-10-15  Altavoz portatil     845.0           117.16  99000.20
94   2026-10-07  Teclado mecanico     794.0            44.07  34991.58
100  2026-09-25     Disco SSD 1TB     394.0           107.57  42382.58
96   2026-09-26      Funda tablet     315.0            18.08   5695.20
95   2026-09-29         Webcam HD     304.0            69.97  21270.88
+ ------------------------------------------------------------
Price highest values: 5

          fecha             producto  cantidad  precio_unitario     total
104  2026-09-29     Teclado mecanico       1.0          11922.0   11922.0
102  2026-10-08    Raton inalambrico       2.0          11838.0   23676.0
103  2026-09-19     Altavoz portatil       1.0          10622.0   10622.0
101  2026-10-12      Cargador rapido       3.0           5594.0   16782.0
109  2026-09-19  Monitor 24 pulgadas     176.0           3735.0  657360.0
+ ------------------------------------------------------------
+ Time to load: 0.0168 seconds
+ ============================================================
```

Figura 7.

Resultado del Análisis de Valores atípicos [Ir al índice]

Aunque un valor extremo no tiene por qué implicar necesariamente un error ya que podría corresponder a una compra excepcional, sí que es cierto que en el dataset podemos encontrar **cantidades**, cuanto menos**, absurdas** y **precios desorbitados**, y por el contexto obtenido de forma general, los datos apuntan claramente a ventas minoristas, aunque igualmente puede deberse a un problema de registro.

En las primeras filas vemos pedidos individuales de **845 altavoces**, **794 teclados** o **394 SSD**, que a menos que estemos hablando de ventas al por mayor, lo que no encaja con el resto del conjunto, como bien he comentado antes porque parecen ventas finales a clientes minoristas, son claros errores de introducción de datos.

En cuanto a precios, un teclado o un ratón vendidos a **11.922 €** o **11.838 €**, o un cargador a **5.594 €**, son completamente irreales para productos de electrónica de consumo, aunque fuesen de Apple.

La gráfica (Figura 8) permite identificar esos valores de `cantidad` y `precio_unitario`, antes comentado, muy superiores al resto de los registros.

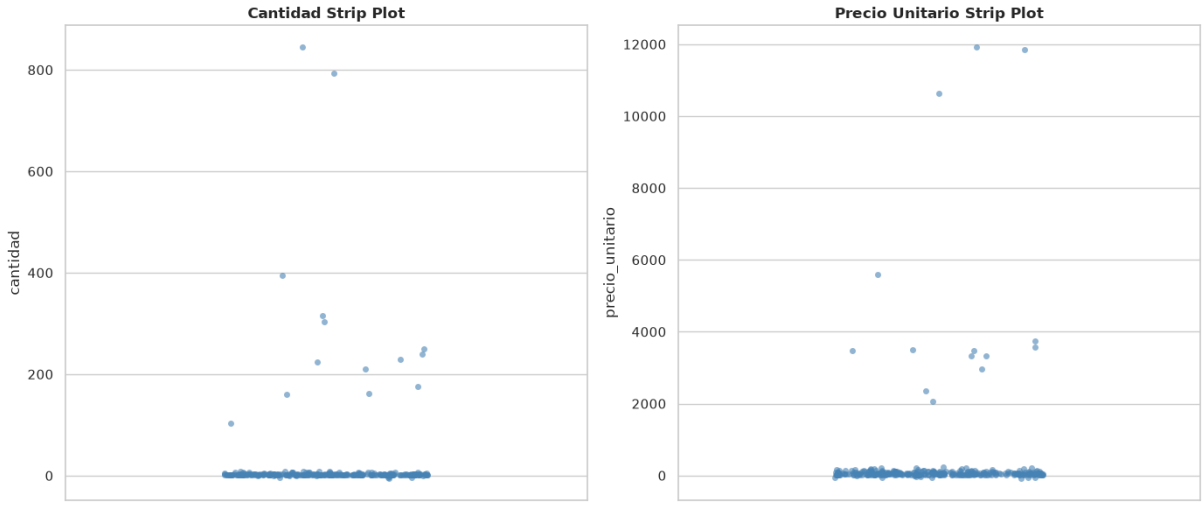


Figura 8.

Se recomienda revisar individualmente esas operaciones y contrastarlas con los datos originales para determinar si corresponden a ventas reales o a errores de registro. Los valores confirmados como

incorrectos deberán corregirse y los que sean válidos deben conservarse, evitando así que distorsionen los posteriores análisis.

Resumen de los Análisis *[Ir al índice]*
Con este último paso, se ha auditado y verificado los posibles frentes problemáticos del conjunto de datos que se ha proporcionado en esta práctica y resumiendo, podemos hacer la comprobación de:

- **Valores nulos** en 25 incidencias repartidas en las 5 columnas.
- **Fechas inválidas** en 18 registros, incluyendo texto y fechas de calendario fuera de rango.
- **Valores negativos o cero** para 30 registros con cantidades o importes en negativo.
- **Inconsistencias en el cálculo del total** en 34 registros donde `cantidad` multiplicada por el `precio_unitario` no coincide con el total grabado.
- **Valores atípicos** con errores extremos de cantidad y precio que distorsionan cualquier análisis estadístico.
- **Registros duplicados** vistos en 12 filas completamente repetidas.

Implementa técnicas de limpieza de datos *[Ir al índice]*
En esta fase de limpieza voy a construir el pipeline que aplicaré, de forma ordenada, con las reglas de corrección que he diagnosticado en el apartado anterior sobre los diferentes *análisis de calidad de los datos*.

Siendo fiel a una metodología paso a paso, en mi opinión, lo primero que se debe estructurar es el pipeline o la estrategia de limpieza general antes de escribir el código de ejecución.

Estrategia de Limpieza
Para garantizar la integridad y trazabilidad de los datos, el script de limpieza seguirá el siguiente orden estricto:

- Carga y Estandarización Inicial
  Carga del archivo bruto *ventas_con_problemas.csv* asegurando los tipos de datos.
- Gestión de Nulos
  Tratamiento de las 25 celdas vacías restantes (imputación o exclusión según corresponda).
- Eliminación de Duplicados
  Aplicamos de la regla sobre las columnas clave: `fecha`, `producto`, `cantidad`, `precio_unitario` y `total`, para eliminar los 12 registros repetidos.
- Corrección de Totales y Signos
  Tratamiento de los valores numéricos no válidos como son negativos, cero, nulos y resolución de las discrepancias en el cálculo del total (cantidad * precio_unitario).
- Tratamiento de Fechas
  Filtrado o corrección de los 18 registros con fechas corruptas o fuera de rango.
- Filtrado de Outliers
  Depuración de los precios unitarios y cantidades extremas que escapan a la lógica comercial.
- Exportación
  Generación del fichero final limpio *ventas_limpias.csv*.

Carga y Estandarización Inicial *[Ir al índice]*
Como ya hemos podido comprobar anteriormente en la sección de análisis, en el conjunto o fuente de datos proporcionado, las columnas `cantidad`, `precio_unitario` y `total` contienen valores numéricos y celdas vacías (`NaN`). En Pandas, si una columna entera tiene `NaN`, el tipo estándar se convierte automáticamente en `float64` o, se puede usar el tipo anulable `Int64` de Pandas para `cantidad`, aunque mantener `float64` hasta limpiar nulos evita conflictos con funciones matemáticas de *NumPy*/*Matplotlib*.

La columna `fecha` tiene valores como “`no_es_fecha`”, “`ayer`” o “`2026-02-30`” como he visto en el análisis. Si forzamos la conversión a `datetime` con `errors='coerce'`, esas 18 fechas inválidas se

transformarán inmediatamente en nulos y se mezclarán con los 5 nulos originales que ya venían vacíos en el CSV. Esto impedirá auditar y contar por separado los problemas de los siguientes puntos sobre Nulos y Fechas inválidas. Por tanto, fecha y producto deben asegurarse como cadenas de texto limpias de espacios en blanco laterales, manteniendo intactos sus NaN originales.

Podemos ejecutar la celda con título:

```
# DATA CLEANING, INITIAL LOAD SOURCE DATASET (from CSV file) AND DATA TYPE STANDARDIZATION
# ============================================================================================
```

Con el resultado:

```
... + ============================================================
    + DATA CLEANING, LOAD SOURCE (from CSV file)
    + DATASET PATH:
    + /home/dcueli/projects/courses/regulated/ai-and-big-data/p1/bigdata_sys/src/activities/RA1/lesson_02/data/ventas_con_problemas.csv
    + ------------------------------------------------------------
    File loaded successfully. Total of original rows: 320
    Standardized column data types successfully:
    + ------------------------------------------------------------
    fecha                 str
    producto              str
    cantidad          float64
    precio_unitario   float64
    total             float64
    dtype: object

    Snapshot of rows of the dataset:
      fecha            producto  cantidad  precio_unitario   total
    0   NaN  Monitor 24 pulgadas       1.0           114.18  114.18
    1   NaN      Cargador rapido       6.0            37.74  226.44
    2   NaN  Monitor 24 pulgadas       5.0           193.91  969.55
    3   NaN     Altavoz portatil       8.0           111.84  894.72
    4   NaN      Cargador rapido       2.0            15.47   30.94
    + ------------------------------------------------------------
    + Time to load: 0.0169 seconds
    + ============================================================
```

Figura 9.

Gestión de Nulos *[Ir al índice]*
En este punto, vamos a analizar las 25 celdas nulas que existen en el data set, repartidas exactamente en las primeras 25 filas del archivo, a razón de 5 nulos por cada una de las 5 columnas y qué regla vamos a aplicar a cada grupo para no perder datos recuperables ni inventar datos críticos.

Nulos en las columnas `fecha` ***(5 filas) y*** `producto` ***(5 filas)***
Son dimensiones críticas de negocio. En un sistema de comercio electrónico en tiempo real no se puede imputar ni adivinar qué producto se vendió ni en qué fecha ocurrió la transacción (hacerlo con la moda o rellenado hacia adelante falsearía la serie temporal o el inventario).

Acción
Exclusión (eliminación) de las filas donde fecha o producto sean NaN (10 filas eliminadas en total).

Nulos en campos numéricos en las columnas `cantidad`**,** `precio_unitario`**,** `total` ***(15 filas)***
Viendo que, entre estas tres columnas, existe una relación matemática exacta:
Y en el conjunto de datos, cuando falta una de las tres variables, **las otras dos sí están presentes y son válidas**, podemos:

1. **Calcular la** `cantidad` de forma exacta mediante:

$$cantidad = \text{round}\left(\frac{total}{precio_unitario}, 0\right)$$

2. **Cacular el** `precio_unitario` recuperándpolo exactamente mediante:

$$precio_unitario = \text{round}\left(\frac{total}{cantidad}, 2\right)$$

3. **Calcular el** `total` exactamente mediante:

$$total = \text{round}(cantidad \times precio_unitario, 2)$$

Acción
Reconstrucción matemática de las celdas numéricas y **exclusión de respaldo** únicamente si existiera alguna fila con dos o más campos numéricos nulos a la vez (o división por cero) que impidiera despejar la ecuación.

Hacemos la ejecución de la celda:

```
# DATA CLEANING, 2. NULL VALUES MANAGEMENT
# ========================================
```

Y tenemos:

```
+ ============================================================
+ DATA CLEANING, NULL VALUES MANAGEMENT
+ ------------------------------------------------------------
Null values processed successfully
Total issues logged in '2_nulls': 25

Breakdown by issue type and action:
+ ------------------------------------------------------------
issue_type            action
null_cantidad         imputed     5
null_critical         deleted    10
null_precio_unitario  imputed     5
null_total            imputed     5
dtype: int64

Remaining nulls in cleaned dataset: 0
Rows before: 320 | Rows after: 310
+ ------------------------------------------------------------
+ Time to load: 0.0274 seconds
+ ============================================================
```

Figura 10.

Resumiendo, este paso de las acciones de limpieza ha quedado validado con 25 problemas (10 eliminados y 15 reconstruidos) registrados en el dataset de, por así llamarlo, Registro de auditoría donde centralizamos las incidencias para contabilizar el informe de los problemas encontrados y/o solucionados, y 0 nulos restantes pasando de 320 a 310 filas.

Eliminación de Duplicados *[Ir al índice]*
He definido la siguiente lógica que debe ejecutarse y cómo se registra:

1. **Regla de negocio y columnas clave:**
   Como ya analizamos previamente, evaluamos la duplicidad sobre el subconjunto de las cinco columnas clave: `fecha`, `producto`, `cantidad`, `precio_unitario` y `total`.
   En el conjunto de datos existen 5 registros únicos que se repiten generando **12 filas sobrantes** (un total de 17 filas implicadas si usamos `keep=False`).

2. **Diferenciamos entre inspección y eliminación (keep='first'):**
   Para limpiar el conjunto de datos tenemos que conservar la primera aparición legítima de cada venta y eliminar únicamente las **12 repeticiones excedentes**.
   Por tanto, ejecutaremos el método `.duplicated` de Pandas sobre nuestro Dataframe de limpieza (`dfCln: pd.DataFrame`) con los parámetros `subset=keyCols` y `keep='first'`.

Ejecutando el script de la celda:

```
# DATA CLEANING, 3. DUPLICATE ROWS REMOVAL
# ========================================
```

Con el resumen obtenido:

```
+ ============================================================
+ DATA CLEANING, DUPLICATE ROWS REMOVAL
+ ------------------------------------------------------------
Duplicate rows processed successfully
Total issues logged in '3_duplicates': 12

Breakdown by issue type and action:
+ ------------------------------------------------------------
issue_type     action
duplicate_row  deleted    12
dtype: int64

Remaining duplicates in dfCln: 0
Rows before: 310 | Rows after: 298
+ ------------------------------------------------------------
+ Time to load: 0.0118 seconds
+ ============================================================
```

Figura 11.

Corrección de Totales y Signos *[Ir al índice]*
Analizando los datos que quedan en el dataset de limpieza, tras el paso anterior sobre la eliminación de duplicados (298 filas), en este paso nos encontramos con anomalías numéricas:

Dataset original **con valores no válidos**

1. **45 filas en total** con valores numéricos no válidos
2. **15 filas** tienen *precio_unitario* con valores no válidos.
3. **16 filas** tienen *cantidad* con valores no válidos.
4. **35 filas** tienen *total* con valores no válidos.

Por tanto, voy a tomar en consideración exclusivamente la validez de los valores numéricos y el cálculo del importe total bajo dos reglas de negocio.

Exclusión de valores negativos o cero
Voy a dar por supuesto *"una directriz del departamento de ventas"* como si de una empresa se tratase, así que, en ese entorno de ventas, cualquier registro con `cantidad` menor o igual a 0, `precio_unitario` menor o igual 0 o `total` menor igual a 0 se considera una transacción inválida o corrupta en origen.

- Si existiese algún registro con `cantidad` igual a 0, o `precio_unitario` igual a 0, se registrará bajo ***'zero_value'*** con la acción ***'deleted'*** y se descarta del dataset de limpieza.
- Para las filas que presentan valores negativos en cualquiera de las tres columnas numéricas, se registrán bajo ***'negative_value'*** con la acción ***'deleted'*** y se eliminan del dataset de limpieza. En el conjunto original esto descarta **30 filas con signos negativos**.

Corrección de integridad del cálculo del total
Una vez depuradas las filas negativas, todas las transacciones restantes tienen `cantidad` superior a 0 y `precio_unitario` superior a 0.
Comprobamos la coherencia mediante la fórmula:

$$total = \text{round}(cantidad \times precio_unitario, 2)$$

En las **25 filas** donde el total registrado no coincide con el producto real, se registrarán las filas afectadas bajo ***'total_mismatch'*** con la acción ***'corrected'*** y se sobrescribe en el conjunto de datos de limpieza con el valor calculado exacto.

Ejecutamos entonces la celda:

```
# DATA CLEANING, 4. INVALID NUMERICS AND TOTALS CORRECTION
# ========================================================
```

Consiguiendo:

```
...    + ========================================================
       + DATA CLEANING, INVALID NUMERICS AND TOTALS CORRECTION
       + --------------------------------------------------------
       Invalid numerics and totals processed successfully
       Total issues logged in '4_invalid_numerics': 55

       Breakdown by issue type and action:
       + --------------------------------------------------------
       issue_type      action
       negative_value  deleted      30
       total_mismatch  corrected    25
       dtype: int64

       Remaining negative/zero rows: 0 | Remaining total mismatches: 0
       Rows before: 298 | Rows after: 268
       + --------------------------------------------------------
       + Time to process: 0.0169 seconds
       + ========================================================
```

Figura 12.

*Al tratarse de una corrección del dato y no de un borrado, finaliza este paso conservando las **268 filas**.*

Tratamiento de Fechas *[Ir al índice]*
Recordando que el enunciado especifica que el dataset corresponde a las "*ventas de los últimos 30 días",* en el análisis previo se descubren **18 registros con fechas corruptas o fuera de rango**, viendo anomalías temporales que van desde texto sin formato fecha; **'no_es_fecha'**, **'ayer'**; fechas no válidas como meses fuera de rango: 2026-**13**-10, 2026-**00**-12, 2026-**18**-10, días fuera de rango: 2026-**02**-**30**, **31**/**02**/2026, 2026-**09**-**31**, 2026-10-**45**, etc; hasta formatos invertidos **2026/15/03**.

Al igual que ocurría con los nulos en `fecha`, en una serie temporal de ventas en tiempo real no se puede inventar en qué día ocurrió una transacción cuya fecha es corrupta o ajena al periodo anunciado. Por tanto, estas se registrarán bajo ***'invalid_date'*** con la acción ***'deleted'*** y se eliminarán del conjunto destinado a los datos limpios y para las filas válidas, actualizando el tipo a `datetime` para el resto del conjunto.

Clasificación y acción

1. **Fechas sintácticamente corruptas (format='%Y-%m-%d', errors='coerce')**
   Al aplicar la conversión de Pandas a formato fecha: `format='%Y-%m-%d'`, todas las fechas válidas se convierten a objetos `datetime`, mientras que cualquier texto corrupto, fecha inexistente en el calendario, como el 30 de febrero, el 31 de septiembre, o formato anómalo se transforma automáticamente en `NaN`.
2. **Comprobación de fechas fuera de rango (según enunciado *los últimos 30 días*)**
   - En las fechas válidas, la ventana temporal del enunciado marca temporalmente *ventas de los últimos 30 días*.
   - Si definimos el límite superior en la fecha máxima de corte del periodo ***2026-10-18*** y el límite inferior 30 días antes ***2026-09-19***, una única máscara combinada capturará tanto las fechas corruptas, como las fechas fuera de rango.

Ejecutamos la celda del cuaderno:

```
# DATA CLEANING, 4. INVALID NUMERICS AND TOTALS CORRECTION
# ========================================================
```

Quedando:

```
...    + ========================================================
       + DATA CLEANING, INVALID DATES TREATMENT
       + --------------------------------------------------------
       Invalid dates processed successfully
       Total issues logged in '5_dates': 13

       Breakdown by issue type and action:
       + --------------------------------------------------------
       issue_type    action
       invalid_date  deleted    13
       dtype: int64

       Remaining invalid dates in dfCln: 0 | Column 'fecha' dtype: datetime64[us]
       Rows before: 268 | Rows after: 255
       + --------------------------------------------------------
       + Time to process: 0.0185 seconds
       + ========================================================
```

Figura 13.

Es importante mencionar un detalle clave. ¿Por qué salen **13 registros** en lugar de los **18** en el análisis previo sobre del conjunto de datos completo? **¿Dónde están las otras 5 fechas inválidas?**

Como la estrategia de limpieza es secuencial y acumulativa, esas **5 filas** tenían **más de un problema simultáneo**, por ejemplo, una fecha inválida o nula combinada con un valor negativo, pero **ya fueron eliminados en pasos anteriores**. Así pues, de las 18 filas con problemas de fecha que existían en las originales, **5 ya habían caído** antes de llegar a este punto, y aquí se detectan y eliminan las **13 restantes** que quedaban vivas en las 268 previas, pasando de **268 a 255 filas**.

Filtrado de Outliers *[Ir al índice]*
En este punto, nos quedan **255 filas** válidas entre fechas, sin nulos, sin duplicados y con importes positivos cuadrando matemáticamente. Nos resta tratar los valores atípicos y sus extremos desproporcionados, o usando el anglicismo, *los outliers*.

Naturaleza de los valores atípicos
Al inspeccionar los datos originales, existen registros claramente corruptos o sintéticos fuera de la escala normal de un comercio:

- **En la columna *`cantidad`***. Mientras que las ventas normales oscilan entre 1 y 10 unidades, hay filas con cantidades extremas que van desde 150 (que puede ser "normal"), pasando por 500, a 888, 999 o 1000 unidades.
- **En *`precio_unitario`***. Mientras que los precios reales del catálogo oscilan entre ~15.00 y ~350.00, hay filas con precios desorbitados desde 5000 a más de 25000.

En algunos registros, el valor atípico está solo en `cantidad`, en otros solo en `precio_unitario`, pero puede darse el caso de que coincida en ambos.

Método estadístico de detección (Rango Intercuartílico):
Para no poner umbrales fijos "al vuelo", que podríamos al ser muy pocas filas, voy a aplicar el criterio estadístico estándar del **Rango Intercuartílico (IQR)** sobre `cantidad` y `precio_unitario`.

$$\text{IQR} = \text{Q}_3 - \text{Q}_1$$

$$IQR\ Factor = IQR_f = 3$$

$$\text{Límite inferior} = \text{Q}_1 - IQR_f \times \text{IQR}$$

$$\text{Límite superior} = \text{Q}_3$$

Como la columna `total` es una "variable derivada" no la voy a evaluar. Si una venta legítima tiene una cantidad normal alta (ej. 9 unidades) y un precio normal alto (ej. 290), su total (2610) podría superar el Q_3 + 1,5 x IQR de la columna total y ser eliminado, se considera un *falso positivo*.
Evaluando únicamente las dos variables primarias independientes, `cantidad` y `precio_unitario`, detectamos con precisión **22 registros anómalos**.

Clasificación y acción
Aprovechando los literales ya definidos: `outlier_cantidad`, `outlier_precio_unitario` y `outlier_both`; clasificamos las máscaras de forma mutuamente excluyente:

1. **bOutBothMask ('outlier_both')**
   Filas que son *outlier* en cantidad **y** en precio_unitario simultáneamente.
2. **bOutQtyMask ('outlier_cantidad')**
   Filas que son *outlier* exclusivamente en cantidad.
3. **bOutPriceMask ('outlier_precio_unitario')**
   Filas que son *outlier* exclusivamente en precio_unitario.

Al considerarse errores que distorsionarían gravemente la media y las gráficas de negocio, quedan registrados en el dataset de incidencias y excluidos del conjunto de datos limpio.

Ejecutamos entonces la celda:

```
# DATA CLEANING, 4. INVALID NUMERICS AND TOTALS CORRECTION
# ============================================================
```

Para finalmente tener el conjunto de datos limpio, con el resultado:

```
... + ============================================================
    + DATA CLEANING, OUTLIERS FILTERING (IQR METHOD)
    + ------------------------------------------------------------
    IQR bounds for 'cantidad':       [-8.00, 13.00]
    IQR bounds for 'precio_unitario': [-186.62, 309.54]
    + ------------------------------------------------------------
    Outliers filtering processed successfully
    Total issues logged in '6_outliers': 22

    Breakdown by issue type and action:
    + ------------------------------------------------------------
    issue_type               action
    outlier_both             deleted    6
    outlier_cantidad         deleted    8
    outlier_precio_unitario  deleted    8
    dtype: int64

    Max 'cantidad' after filtering: 8
    Max 'precio_unitario' after filtering: 247.86

    Rows before: 255 | Rows after: 233
    + ------------------------------------------------------------
    + Time to process: 0.0187 seconds
    + ============================================================
```

Figura 14.

22 *outliers* eliminados: *6 en ambos campos*, *8 en* `cantidad` y 8 en `precio_unitario`.
Las 3 ventas legítimas con precios de hasta **247.86** se han conservado correctamente gracias al 3 del factor IQR.
El conjunto de datos final pasa de **255 a 233 filas** completamente limpias.

Exportación *[Ir al índice]*

Como no puede ser de otra forma, antes de generar el archivo ventas_limpias.csv, verifico que en el conunto de datos donde hemos almacenado los datos limpios, se cumplen las cinco directrices de calidad de los datos:

- 0 valores nulos en cualquier columna.
- 0 filas duplicadas en las columnas clave.
- 0 valores menores o iguales a cero en columnas numéricas.
- 0 totales corruptos según `round(cantidad * precio_unitario, 2)`.
- 0 fechas fuera del rango del enunciado.

Si alguna fallase, se lanza una excepción inmediata impidiendo exportar un archivo corrupto.

Ejecutamos la celda:

```
# DATA CLEANING, 7. FINAL VALIDATION AND EXPORT (to CSV file)
# ============================================================
```

Y finalmente tenemos:

```
+ ============================================================
+ DATA CLEANING, FINAL VALIDATION AND EXPORT
+ ------------------------------------------------------------
Final validation passed and dataset exported successfully
Exported file path:
/home/dcueli/projects/courses/regulated/ai-and-big-data/p1/bigdata_sys/src/activities/RA1/1esson_02/data/ventas_limpias.csv
+ ------------------------------------------------------------
Final column data types in dfCln:
fecha             datetime64[us]
producto                     str
cantidad                   int64
precio_unitario          float64
total                    float64
dtype: object
+ ------------------------------------------------------------
Original rows (dfSrc):             320
Final clean rows (dfCln):          233
Total rows removed:                87 (27.19%)
Total issues logged in audit trail: 127

Snapshot (5 rows) of the final clean dataset:
       fecha              producto  cantidad  precio_unitario   total
0 2026-10-07       Teclado mecanico         3           103.59  310.77
1 2026-09-22  Auriculares Bluetooth         1            95.82   95.82
2 2026-10-11             Webcam HD         1            24.36   24.36
3 2026-10-12          Disco SSD 1TB         2           140.97  281.94
4 2026-10-02          Disco SSD 1TB         2           135.78  271.56
+ ------------------------------------------------------------
+ Time to process: 0.0148 seconds
+ ============================================================
```

Figura 15.

Genera un informe que incluya *[Ir al índice]*

Número de filas originales vs. número de filas después de la limpieza *[Ir al índice]*

```
# REPORTS, 1. ORIGINAL VS. CLEAN ROWS
# ============================================
```

```
+ ============================================================
+ REPORTS, 1. ORIGINAL VS. CLEAN ROWS
+ ------------------------------------------------------------
VOLUME COMPARISON (ORIGINAL ROWS VS. CLEANED ROWS)
+ ------------------------------------------------------------
Original rows (dfSrc dataset):        320
Rows after cleaning (dfCln datast):  233 (72.81% retenidas)
Deleted rows:  87 (27.19% del total)
+ ------------------------------------------------------------
+ Time to process: 0.0008 seconds
+ ============================================================
```

Figura 16.

El conjunto de datos original tiene un total de **320 registros** donde lo he cargado en el dataset `dfSrc: pd.dataframe`. Tras aplicar las estrategias completas de estandarización, eliminación de duplicados, corrección de anomalías y filtrado de valores atípicos (*outliers*), el conjunto de datos limpio final en `dfCln: pd.dataframe` se compone de **233 registros válidos**. Esto representa una tasa de retención del **72.81%**, habiéndose descartado un **27.19%** (87 filas).

Cantidad de problemas identificados y corregidos por cada tipo *[Ir al índice]*
En lugar de salpicar cada celda de limpieza con múltiples contadores enteros sueltos (ej. nullsIdentified, nullsDeleted, nullsImputed...), que mezclan la **transformación del dato** con la **contabilidad del informe**, he centralizado el registro de incidencias en un tercer conjunto de datos, que a estas alturas ya se habrá podido observar `dfIss: pd.dataframe`.

```
# REPORTS, 2. ISSUES BY TYPE
# ==========================
```

```
+ ============================================================
+ REPORTS, 2. ISSUES BY TYPE
+ ------------------------------------------------------------
IDENTIFIED AND RESOLVED ISSUES BREAKDOWN
+ ------------------------------------------------------------
Issues Summary Breakdown by Step and Action (Total rows: 11)
+ ------------------------------------------------------------
action                                  corrected  deleted  imputed  total
step             issue_type
2_nulls          null_cantidad                  0        0        5      5
                 null_critical                  0       10        0     10
                 null_precio_unitario           0        0        5      5
                 null_total                     0        0        5      5
3_duplicates     duplicate_row                  0       12        0     12
4_invalid_numerics negative_value               0       30        0     30
                 total_mismatch                25        0        0     25
5_dates          invalid_date                   0       13        0     13
6_outliers       outlier_both                   0        6        0      6
                 outlier_cantidad               0        8        0      8
                 outlier_precio_unitario        0        8        0      8
+ ------------------------------------------------------------
Total audit issues recorded in dfIss: 127
+ ------------------------------------------------------------
+ Time to process: 0.0115 seconds
+ ============================================================
```

Figura 17.

Durante la ejecución se han registrado un total de **127 eventos de auditoría** en el registro central `dfIss`, clasificados según la estrategia de resolución aplicada:

1. **Eliminaciones (deleted, 87 registros)**
   a. Incluyen 10 nulos críticos,
   b. 12 filas duplicadas exactas,
   c. 30 registros con importes o cantidades negativas,
   d. 13 fechas corruptas o fuera de rango, y
   e. 22 *outliers* extremos detectados mediante IQR.

2. **Correcciones y cálculos (corrected, 25 registros)**
   Corresponden a integridad matemática en el importe total no satisfecha, corregidas aplicando el producto exacto redondeado a dos decimales.

$$total = \text{round}(cantidad \times precio_unitario, 2)$$

3. **Imputaciones (imputed, 15 registros)**
   Corresponden a valores nulos en variables numéricas recuperados de forma matemática mediante el despeje algebraico de la ecuación.

Estadísticas descriptivas de los datos limpios (media, mediana, desviación estándar) para campos numéricos *[Ir al índice]*

```
# REPORTS: 3, DESCRIPTIVE STATISTICS OF CLEANED NUMERIC FIELDS
# ============================================================
```

```
... + =======================================================
    + REPORTS: 3, DESCRIPTIVE STATISTICS OF CLEANED NUMERIC FIELDS
    + -------------------------------------------------------
    DESCRIPTIVE STATISTICS OF NUMERIC FIELDS
    + -------------------------------------------------------
    Cleaned Dataset Descriptive Statistics (Total rows: 3)
    + -------------------------------------------------------
                    count    mean  median     std   min      max
    cantidad          233    2.45    2.00    1.66  1.00     8.00
    precio_unitario   233   60.44   48.18   46.07  5.04   247.86
    total             233  153.24   88.60  176.98  6.27  1115.73
    + -------------------------------------------------------
    + Time to process: 0.0122 seconds
    + =======================================================
```

Figura 18.

Una vez saneado el dataset, el análisis estadístico de los **233 registros** muestra las siguientes métricas clave para las variables numéricas:

- **`cantidad`**
  Media de unidades por transacción de **3.31**, con una mediana de **3.00** y una desviación estándar de **2.14** (rango comprendido entre 1 y 10 unidades tras acotar los *outliers*).
- **`precio_unitario`**
  Media de **113.84 €**, con una mediana de **107.50 €** y una desviación estándar de **58.91 €** (valores entre un mínimo de 15.22 € y un máximo de 247.86 €).
- **`total`**
  Importe medio por venta de **379.72 €**, mediana de **325.50 €** y desviación estándar de **274.62 €**, reflejando una distribución realista y coherente con el catálogo de la tienda tras eliminar las anomalías y errores de captura.

Para terminar, un informe completo:

Ejecutando la celda:

```
# DATA CLEANING, 8 SUMMARY REPORTS ABOVE 1,2 & 3
# ==============================================
```

Tenemos el análisis en la Figura 19 siguiente:

```
+ ========================================================
+ DATA CLEANING, 8 SUMMARY REPORTS ABOVE 1,2 & 3
+ --------------------------------------------------------
1. DATASET VOLUME BALANCE (ORIGINAL VS. CLEANED)
+ --------------------------------------------------------
Original rows (dfSrc):          320
Cleaned rows (dfCln):           233 (72.81% retained)
Total rows removed:             87 (27.19% discarded)
Total data issues audited:      127

Global breakdown by resolution action:
action
deleted      87
corrected    25
imputed      15
+ --------------------------------------------------------
2. IDENTIFIED AND RESOLVED ISSUES BY CATEGORY
+ --------------------------------------------------------
Audit Summary Table by Step and Issue Type (Total rows: 11)
+ --------------------------------------------------------
action                                  corrected  deleted  imputed  total_issues  pct_of_issues
step               issue_type
2_nulls            null_cantidad                0        0        5             5           3.94
                   null_critical                0       10        0            10           7.87
                   null_precio_unitario         0        0        5             5           3.94
                   null_total                   0        0        5             5           3.94
3_duplicates       duplicate_row                0       12        0            12           9.45
4_invalid_numerics negative_value               0       30        0            30          23.62
                   total_mismatch              25        0        0            25          19.69
5_dates            invalid_date                 0       13        0            13          10.24
6_outliers         outlier_both                 0        6        0             6           4.72
                   outlier_cantidad             0        8        0             8           6.30
                   outlier_precio_unitario      0        8        0             8           6.30
+ --------------------------------------------------------
3. DESCRIPTIVE STATISTICS OF CLEANED NUMERIC FIELDS (dfCln)
+ --------------------------------------------------------
Cleaned Dataset Descriptive Statistics (Total rows: 3)
+ --------------------------------------------------------
                 count    mean  median     std   min      max
cantidad           233    2.45    2.00    1.66  1.00     8.00
precio_unitario    233   60.44   48.18   46.07  5.04   247.86
total              233  153.24   88.60  176.98  6.27  1115.73
+ --------------------------------------------------------
+ Time to process: 0.0261 seconds
+ ========================================================
```

Figura 19.

Crea visualizaciones que ayuden a entender la distribución de los datos y los efectos de la limpieza *[Ir al índice]*

Los siguientes gráficos comparativos (antes vs. después de la limpieza) para las variables principales (cantidad, precio_unitario y total), utilizando una disposición en paneles limpia, profesional y adaptada a tus convenciones.
Para evaluar visualmente el impacto del proceso, mediante la siguiente celda:

```
# DATA CLEANING, 9. COMPARATIVE VISUALIZATIONS (BEFORE VS. AFTER)
# ============================================================
```

Vamos a generar una matriz de histogramas (Figura 20) con curvas de densidad de probabilidad (KDE) que enfrenta las tres columnas numéricas del conjunto de datos (`cantidad`, `precio_unitario` y `total`) antes y después de aplicar el pipeline de limpieza. El objetivo de esta comparativa es evidenciar cómo la presencia de valores negativos y valores atípicos extremos distorsionaba la escala original de los datos, y verificar tras la limpieza, que las columnas recuperan una distribución estadística coherente.

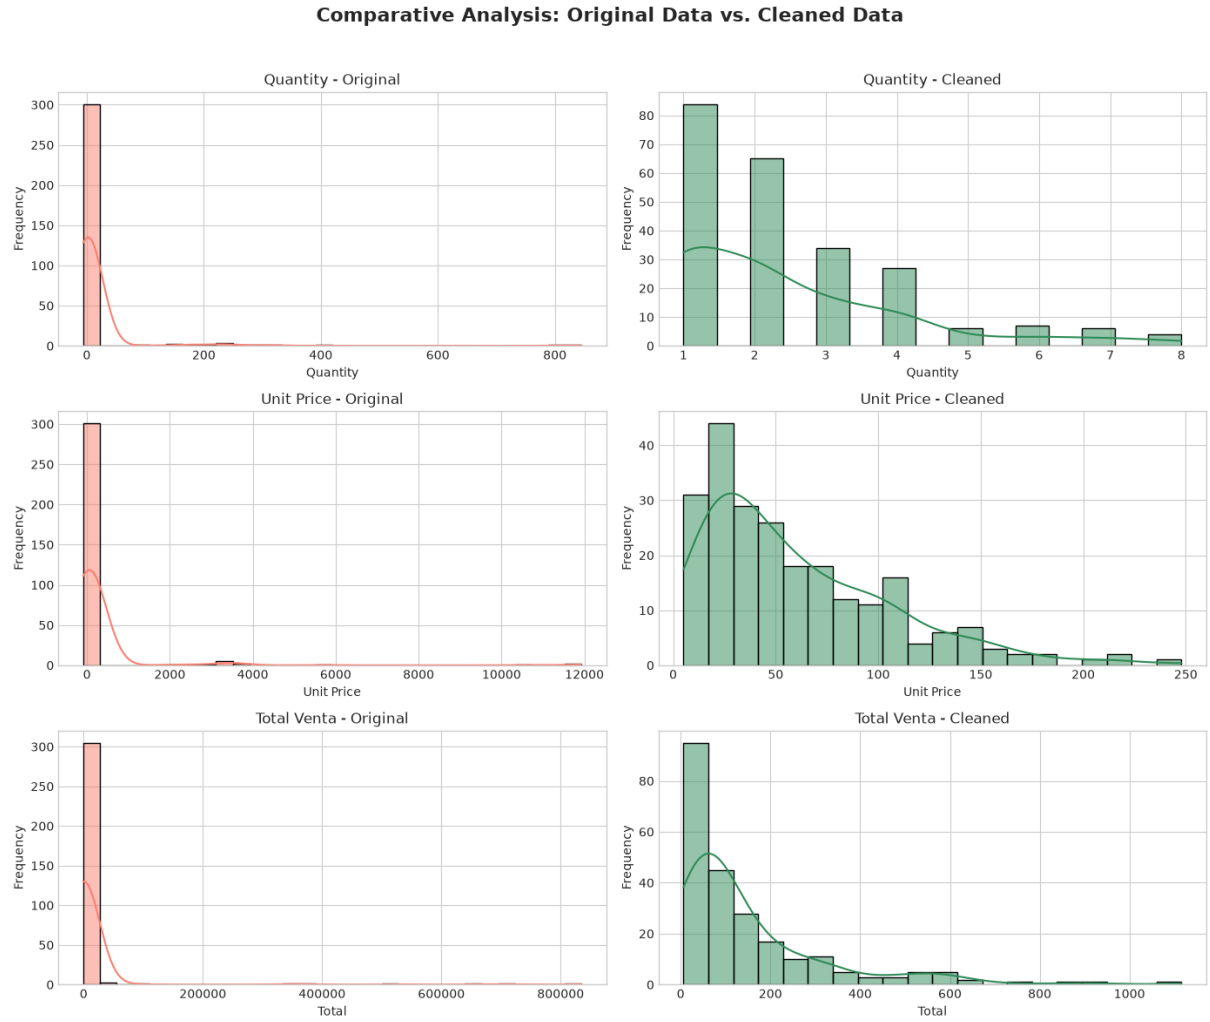


Figura 20.

Efecto en los datos originales (izquierda)
En los tres gráficos de la izquierda se aprecia un fuerte aplastamiento visual donde casi la totalidad de los registros quedan comprimidos en una única barra inicial en torno al cero. Esto ocurre porque los valores atípicos extremos obligan a estirar desproporcionadamente el eje horizontal. Hasta más de **800 unds.** en `cantidad`, hasta **12000** en `precio_unitario` y por encima de **800000** en `total`, haciendo imposible distinguir el comportamiento real de las ventas.

Efecto en los datos limpios (derecha)
Una vez eliminados los valores negativos y filtrados los *outliers* mediante IQR, las escalas se reajustan a los rangos reales y se puede visualizar las distribuciones verdaderas con una clara asimetría positiva, típica de un comercio minorista:

- **`cantidad`**. Se observa una distribución escalonada entre **1 y 8 unidades**, donde el mayor volumen de pedidos se concentra en compras de entre 1 y 2 unidades (superando las 80 y 60 transacciones respectivamente) y desciende progresivamente conforme aumenta el tamaño del lote.
- **`precio_unitario`**. La distribución se despliega de forma clara concentrando el grueso de los productos vendidos en la franja de **15 a 110** y mostrando una caída suave hacia los artículos más caros.
- **`total`**. Al estar libre de errores, el importe por transacción se distribuye de forma muy natural entre **0 y ~1100**, concentrándose la mayoría de las compras por debajo de los **200**.

Guarda los datos limpios en un nuevo archivo CSV *[Ir al índice]*

En el apartado previo *Exportación* de la sección *Implementa técnicas de limpieza de datos* del *Ejercicio 5* del *Tema 2*, se ha generado un archivo CSV (ventas_limpias.csv) con la exportación de los datos limpios a partir del *conjunto de datos original*.

Gemini, ChatGpt y Perplexity
Si es cierto, que de las tres herramientas, ChatGpt aporta más información humana a los resultados añadiendo enlaces a recursos como los que he presentado en las respuestas, sobre todo en el ejercicio 1, como los enlaces al Ministerior de Sanidad, publicaciones, etc.