

Tema 2: Análisis en Tiempo Real, Modelado de Datos y Evaluación de Costos y Calidad


04/09/2026

Fundamentos de la programación en IA



Modelado de datos

El modelado de datos consiste en representar de forma abstracta como se estructuran de forma real los datos en un sistema o entorno. Generalmente la salida de este proceso suelen ser diagramas que representan los flujos de datos en su entorno, es decir, una base de datos. En este diagrama definiremos el formato y la estructura de los datos




Modelado de datos

Representación de alto nivel de las entidades, atributos y relaciones dentro del dominio del problema sin preocuparse de como se almacenarán los datos directamente.

En ellas incluimos clases de entidad, sus características y restricciones, las relaciones entre ellas y los requisitos relevantes de seguridad e integridad de los datos.

No especificamos ni atributos ni claves principales.


Modelo conceptual



Modelado de datos

Representación detallada del modelo conceptual previamente realizado, especificamos el tipo de datos, claves primarias y foráneas, pero aún es independiente del Sistema de Gestión de Bases de Datos (SGBD). La intención del modelo es profundizar y detallar el modelo anterior, pero sin especificar detalles técnicos del sistema. Es una etapa que a veces se pasa por alto y simplemente se diseñan el modelo físico y conceptual, pero es de vital importancia para proyectos altamente procedimentales o cuyo objetivo sea trabajar con datos (como el diseño de una base de datos).


Modelo lógico



Modelado de datos

Este modelo describe cómo los datos serán almacenados en un SGBD específico. Incluye detalles como tipos de datos específicos del sistema, índices, particiones, y otros aspectos de optimización del rendimiento. Podríamos decir que en este esquema podremos observar como se almacenarán los datos específicamente. Ofrece un diseño poco abstracto y que se puede implementar como base de datos relacional.

Modelo físico



Modelado de datos

Modelo conceptual

Característica	Conceptual	Lógico	Física
Nombres de entidades	✓	✓	
Relaciones de entidades	✓	✓	
Atributos		✓	
Tecclas principales		✓	✓
Foreign Keys		✓	✓
Nombres de tabla			✓
Nombres de columnas			✓
Tipos de datos de columna			✓


Modelos de bases de datos

En este apartado trataremos los tipos de modelos de bases de datos más importantes y destacados. Estos modelos representan diferentes maneras de organizar, estructurar y gestionar los datos dentro de un sistema de gestión de bases de datos (SGBD).

Modelos de bases de datos

Modelo jerárquico


Los datos se organizan en estructura de árbol, cada nodo tiene un solo padre pero puede tener varios hijos. Fue el modelo usado por los Sistemas de Gestión de Información de IBM en las décadas de 1960 y 1970 pero hoy no se suele usar. El orden de los elementos de las filas también es importante



Modelos de bases de datos


Es el modelo más común y se basa en la organización de datos en tablas (también llamadas relaciones). Cada tabla contiene filas y columnas, y las tablas pueden estar relacionadas entre sí mediante claves primarias y foráneas. Cada fila incluye datos sobre una instancia específica de la entidad. El modelo también representa los tipos de relaciones entre esas tablas, ya sean 1 a 1, 1 a N o N a N

Modelo relacional



Modelos de bases de datos


Es un modelo de alto nivel que se utiliza para diseñar bases de datos. Se centra en la identificación de entidades (objetos del mundo real) y sus relaciones. Las entidades se representan como rectángulos y las relaciones como rombos en diagramas ER.



Modelos de bases de datos


Similar al modelo jerárquico, pero en lugar de una estructura de árbol rígida, permite que cada nodo tenga múltiples padres, formando una red. Es más flexible que el modelo jerárquico.

Modelo de red



Modelos de bases de datos

Este modelo combina los principios de la programación orientada a objetos con la gestión de bases de datos. Los datos se almacenan en forma de objetos, similares a los objetos en lenguajes de programación como Java o C++.



Técnicas de razonamiento lógico

1 Lógica booleana:

Este tipo de lógica utiliza valores binarios (verdadero/falso) y operadores lógicos como AND, OR, y NOT basándose en esas operaciones explicadas. Es fundamental en la toma de decisiones automatizadas y en la filtración de datos.

2. Razonamiento deductivo:

Consiste en extraer conclusiones específicas verídicas a partir de premisas previas generales. Es útil cuando se quiere aplicar reglas generales a un conjunto de datos para hacer predicciones o identificar patrones.

3. Razonamiento inductivo:

Es el proceso inverso al razonamiento deductivo; se basa en observar patrones específicos para generar reglas generales. Es fundamental en el aprendizaje automático (machine learning). En este caso se puede utilizar un patrón observado para predecir el comportamiento de nuevos clientes o para segmentar mejor a los clientes en grupos con características similares.

Análisis en tiempo real

El modelado de datos consiste en representar de forma abstracta como se estructuran de forma real los datos en un sistema o entorno. Generalmente la salida de este proceso suelen ser diagramas que representan los flujos de datos en su entorno, es decir, una base de datos. En este diagrama definiremos el formato y la estructura de los datos



Análisis en tiempo real


PROCESAMIENTO EN MEMORIA

Utilizamos memoria RAM para almacenar los datos en vez de hacerlo en disco como generalmente. Esto reduce el tiempo de tardamos en acceder a los datos y optimiza el procesamiento aumentando la velocidad.

Los datos son cargados en estructuras de datos (matrices, tablas, etc.) que se almacenan en su totalidad en la memoria, que garantiza un acceso y modificado rápido de los mismos. Esta rapidez reduce notoriamente la latencia al ahorrar el tiempo que necesitábamos para acceder al almacenamiento en disco.

Además, utilizamos mecanismos como snapshots que escriben en disco para recuperar estos datos en caso de ocurrir algún error en memoria y perderlos.


Técnicas avanzadas



Análisis en tiempo real

Técnicas avanzadas

MICRO-BATCHING




Análisis en tiempo real

PROCESAMIENTO DE FLUJO

En esta técnica nos enfocamos en manejar y analizar los datos de forma continua según van llegando de forma continua. Este hecho permite tomar decisiones y realizar operaciones en tiempo real. En este caso el procedimiento es sencillo, se tratan los datos como si fueran eventos individuales y procesados según llegan, haciendo en este momento las transformaciones y análisis.

Este procesado se divide en ventanas de tiempo, para agrupar una serie de eventos y realizar cálculos en conjunto. Algunas aplicaciones que pueden utilizar estas técnicas son sistemas de recomendación o detección de tendencias en redes sociales. En este caso se procesan datos de forma continua según son recibidos sin necesidad de usar lotes como en el anterior

Técnicas avanzadas




Análisis en tiempo real

Técnicas avanzadas

ARQUITECTURA BASADA EN EVENTOS

Basada en la comunicación entre componentes del sistema a través de eventos, los eventos representan cambios en el sistema, y los componentes reaccionan a estos eventos de forma asíncrona.

Para entenderlo mejor, los eventos son mensajes que nos indican que algo ha ocurrido, como por ejemplo la llegada de nuevos datos. Los componentes del sistema se dividen en publicadores (generan eventos) y suscriptores (escuchan y responden). A través de un bus de eventos se distribuyen los eventos entre los componentes interesados.



Análisis en tiempo real

Ventanas deslizantes: se mueven de forma continuada, permitiendo análisis de datos de forma solapada.

Ventanas tumbadas: se dividen en intervalos fijos sin solapamiento de datos.

Ventanas de sesión: basadas en la actividad de usuario, se cierran después de un período de inactividad.

El manejo del estado implica mantener información sobre eventos pasados y actuales para realizar cálculos o análisis complejos. Esto trata de mantener el estado de los datos a lo largo del tiempo, facilitando su seguimiento y agregación en eventos en tiempo real.

Ventanas de tiempo Manejo de estado

Análisis en tiempo real

SISTEMAS MENSAJERÍA Y TRANSMISIÓN DE DATOS

Apache Kafka

Amazon Kinesis

PROCESAMIENTO EN TIEMPO REAL

Apache Flink

Apache Storm

Google Cloud Dataflow

Herramientas

MONITOREO Y VISUALIZACIÓN

Grafana

Kibana



Costes y calidad

Costos de infraestructura

Costos de almacenamiento

Costos de procesamiento

Costos de personal

Costos de licencias y software

Otros

Tipos



Costes y calidad

Costos directos: aquellos costos claramente atribuibles al proyecto de Big Data. Suelen ser los costos más fáciles de identificar y tener en cuenta. Algunos ejemplos podrían ser: infraestructura, almacenamiento, licencias, personal, seguridad o procesamiento.

Costos indirectos; costos no directamente vinculados a un solo proyecto pero que hay que tener en cuenta porque influyen en el presupuesto general. Algunos ejemplos son: Soporte y mantenimiento, energía del centro de datos y refrigeración, costos administrativos, capacitación y formación del personal o pérdida de oportunidades (por retrasos en el proyecto, por ejemplo).

Clasificación



Costes y calidad

Entre los aspectos más importantes que garantizan la calidad de dato encontramos:

- Precisión: un dato debe reflejar fielmente la realidad.
- Integridad: los datos necesarios han de estar presente y completos.
- Consistencia: deben ser coherentes con el sistema.
- Validez: han de cumplir las reglas esperadas.
- Actualidad: deben de estar actualizados

Control de calidad

Profiling de datos: análisis de los datos para detectar patrones o valores atípicos que pueden ser inadecuados para el análisis final.

- Limpieza de datos: proceso de revisión y eliminación de datos inexactos o duplicados. Como ya explicamos en su momento puede conllevar la normalización, eliminación de valores nulos o corrección del formato si no es el adecuado.
- Normalización de los datos: Mencionado en el apartado anterior, se trata de estandarizar unidades de medida y transformar variables categóricas en numéricas
- Monitoreo continuo: nos puede ayudar a identificar problemas de calidad a tiempo real, permitiéndonos detectar anomalías y corregirlas automáticamente.

Costes y calidad

Optimización en la nube
Comprensión y archivado de datos
Selección de herramientas adecuadas

Métodos de optimización

